

TÜRKİYE CUMHURİYETİ
YILDIZ TEKNİK ÜNİVERSİTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



ŞARKI SÖZLERİNDEKİ DUYGULARIN TÜR VE
POPÜLERLİK İLE İLİŞKİSİ

21011702 – Melih YELMAN
21011022 – Tarık TAŞKIN

BİLGİSAYAR PROJESİ

Danışman
Öğr. Gör. Dr. Ayşe Öcal

Haziran, 2025

TEŞEKKÜR

Bu proje süresince danışmanlığımızı üstlenen, ilerleyişimizi takip eden ve bizlere rehberlik eden Öğr. Gör. Dr. Ayşe Öcal hocamıza içten teşekkürlerimizi sunarız. Bu alandaki gelişmeleri öğrenmek ve uygulamak bizim için son derece heyecan verici bir deneyim olmuştur.

Ayrıca, bizlerin akademik ve mesleki gelişimine katkıda bulunan Yıldız Teknik Üniversitesi Bilgisayar Mühendisliği Bölümü'ndeki tüm hocalarımıza da emekleri için ayrı ayrı teşekkür ederiz.

Melih YELMAN

Tarık TAŞKIN

İÇİNDEKİLER

KISALTMA LİSTESİ	vi
ŞEKİL LİSTESİ	viii
TABLO LİSTESİ	x
ÖZET	xi
ABSTRACT	xiii
1 GİRİŞ	1
1.1 Genel Bakış	1
1.2 Doğal Dil İşleme Nedir?	2
1.3 Doğal Dil İşleme Uygulama Alanları	2
1.4 Projenin Amacı	4
2 LİTERATÜR ANALİZİ	5
2.1 Geçmiş Yaklaşımlar	5
2.2 Çıkarımlar	8
3 SİSTEM ANALİZİ ve FİZİBİLİTE	10
3.1 Sistem Analizi	10
3.1.1 Projenin Hedefleri	10
3.1.2 Bilgi Kaynakları ve Gereksinimler	11
3.1.3 Performans Metrikleri ve Başarı Kriterleri	11
3.2 Fizibilite	11
3.2.1 Teknik Fizibilite	11
3.2.2 Yasal Fizibilite	13
3.2.3 Ekonomik Fizibilite	13
3.2.4 İş Gücü ve Zaman Fizibilitesi	14
4 SİSTEM TASARIMI	15
4.1 Materyal ve Veri Kümesi	15
4.1.1 Model Eğitimi İçin Kullanılan Hazır Veri Kümesi	15

4.1.2	Hazır Veri Kümesi Üzerinde Yapılan İşlemler Sonucunda Oluşan Veri Kümeleri	16
4.1.3	Duygu Analizi için Kullanılan Veri Kümesi	19
4.1.4	Veri Kümelerine Uygulanan İşlemler	21
4.1.5	Veri Yapısı ve Saklama Biçimi	22
4.1.6	Augmentasyon İşlemi ve Sınırlama	23
4.2	Metot	23
4.2.1	BERT	23
4.2.2	RoBERTa	24
4.2.3	DeBERTaV3	26
4.2.4	Modellerin Karşılaştırılması	27
5	DENEYSEL SONUÇLAR	29
5.1	Performans Analizi	29
5.1.1	BERT Modeli	29
5.1.2	RoBERTa Modeli	33
5.1.3	DeBERTaV3 Modeli	37
5.2	Karşılaştırmalı Analiz	42
5.2.1	Model Performans Metriklerinin Özeti	42
5.2.2	Modeller Arası Genel Performans Karşılaştırılması	42
5.2.3	Veri Dengeleme Stratejilerinin Model Performansı Üzerindeki Etkileri	43
5.2.4	Duygu Sınıflarına Özgü Gözlemler	44
5.2.5	Genel Sonuçlar	44
5.3	Power Analysis ve Ground Truth	45
5.3.1	Power Analysis	45
5.3.2	Ground Truth	45
5.4	Şarkıların Meta Bilgileriyle Duygu Analizi İlişkileri	47
5.4.1	Duygu Analizi için Kullanılan Veri Setinin Duygu Dağılımı	47
5.4.2	Duygu Analizi için Kullanılan Veri Setinin Duygulara Göre Ortalama Popülerlik Skorları	48
5.4.3	Duygu Analizi için Kullanılan Veri Setinin Duygulara Göre Popülerlik Dağılımı	48
5.4.4	Duygu Analizi için Kullanılan Veri Setinin Türlere Göre Duygu Dağılımı	49
5.4.5	Duygu Analizi için Kullanılan Veri Setinin Tür ve Duygulara Göre Ortalama Popülerlik Skorları Dağılımı	50
5.4.6	Duygu Analizi için Kullanılan Veri Setinin Yıllara Göre Ortalama Popülerlik Trendleri	51

5.4.7	Sonuçların Değerlendirilmesi	51
6	SONUÇ VE TARTIŞMA	53
6.1	Proje Konusunun ve Yöntemlerin Özeti	53
6.2	Elde Edilen Sonuçların Değerlendirmesi	53
6.3	Çalışmanın Güçlü ve Zayıf Yönleri	55
6.3.1	Çalışmanın Güçlü Yönleri	55
6.3.2	Çalışmanın Zayıf Yönleri	55
6.4	Öneriler	56
	Referanslar	57
	Özgeçmiş	60

KISALTMA LİSTESİ

AI	Artificial Intelligence
BERT	Bidirectional Encoder Representations from Transformers
Bi-LSTM	Bidirectional Long Short-Term Memory
CPU	Central Processing Unit
DA	Disentangled Attention
DeBERTaV3	Disentangled and ELECTRA-Based Representation with Gradient-Aware Pretraining
DL	Deep Learning
GDES	Gradient-Disentangled Embedding Sharing
GloVe	Global Vectors for Word Representation
GLUE	The General Language Understanding Evaluation
GPU	Graphics Processing Unit
LSTM	Long Short-Term Memory
MER	Music Emotion Recognition
ML	Machine Learning
MLM	Masked Language Modeling
NLG	Natural Language Generation
NLP	Natural Language Processing
NLU	Natural Language Understanding
NSP	Next Sentence Prediction
RACE	The ReAding Comprehension from Examinations
RoBERTa	A Robustly Optimized BERT Pretraining Approach
RTD	Replaced Token Detection
SQuAD	The Stanford Question Answering Dataset

SVM Support Vector Machine

ŞEKİL LİSTESİ

Şekil 2.1	Plutchik'in Duygu Çarkifeleği	6
Şekil 3.1	Gantt Şeması	14
Şekil 4.1	Veri İşleme Adımları Sonucunda Elde Edilen Hazır Veri Kümesinin Sınıf Dağılımı	16
Şekil 4.2	Dataset 1 Veri Kümesinin Sınıf Dağılımı	17
Şekil 4.3	Dataset 2 Veri Kümesinin Sınıf Dağılımı	18
Şekil 4.4	Dataset 3 Veri Kümesinin Sınıf Dağılımı	19
Şekil 4.5	Duygu Analizi için Kullanılan Veri Kümesinin Yayın Yılına Göre Dağılımı	20
Şekil 4.6	Duygu Analizi için Kullanılan Veri Kümesinin Popülerite Puanlarına Göre Dağılımı	21
Şekil 5.1	Dataset 1 ile Eğitilmiş BERT Modeline Ait Sınıflandırma Raporu	30
Şekil 5.2	Dataset 1 ile Eğitilmiş BERT Modeline Ait Karmaşıklık Matrisi . .	31
Şekil 5.3	Dataset 2 ile Eğitilmiş BERT Modeline Ait Sınıflandırma Raporu	31
Şekil 5.4	Dataset 2 ile Eğitilmiş BERT Modeline Ait Karmaşıklık Matrisi . .	32
Şekil 5.5	Dataset 3 ile Eğitilmiş BERT Modeline Ait Sınıflandırma Raporu	32
Şekil 5.6	Dataset 3 ile Eğitilmiş BERT Modeline Ait Karmaşıklık Matrisi . .	33
Şekil 5.7	Dataset 1 ile Eğitilmiş RoBERTa Modeline Ait Sınıflandırma Raporu	34
Şekil 5.8	Dataset 1 ile Eğitilmiş RoBERTa Modeline Ait Karmaşıklık Matrisi	35
Şekil 5.9	Dataset 2 ile Eğitilmiş RoBERTa Modeline Ait Sınıflandırma Raporu	35
Şekil 5.10	Dataset 2 ile Eğitilmiş RoBERTa Modeline Ait Karmaşıklık Matrisi	36
Şekil 5.11	Dataset 3 ile Eğitilmiş RoBERTa Modeline Ait Sınıflandırma Raporu	36
Şekil 5.12	Dataset 3 ile Eğitilmiş RoBERTa Modeline Ait Karmaşıklık Matrisi	37
Şekil 5.13	Dataset 1 ile Eğitilmiş DeBERTaV3 Modeline Ait Sınıflandırma Raporu	39
Şekil 5.14	Dataset 1 ile Eğitilmiş DeBERTaV3 Modeline Ait Karmaşıklık Matrisi	39
Şekil 5.15	Dataset 2 ile Eğitilmiş DeBERTaV3 Modeline Ait Sınıflandırma Raporu	40
Şekil 5.16	Dataset 2 ile Eğitilmiş DeBERTaV3 Modeline Ait Karmaşıklık Matrisi	40
Şekil 5.17	Dataset 3 ile Eğitilmiş DeBERTaV3 Modeline Ait Sınıflandırma Raporu	41

Şekil 5.18 Dataset 3 ile Eğitilmiş DeBERTaV3 Modeline Ait Karmaşıklık Matrisi	41
Şekil 5.19 Etiketleri Ortak Belirlenmiş Veri Kümesinin Sınıf Dağılımı	46
Şekil 5.20 Ground Truth Kapsamında Elde Edilen Sınıflandırma Raporu . .	46
Şekil 5.21 Ground Truth Kapsamında Elde Edilen Karmaşıklık Matrisi	47
Şekil 5.22 Duygu Analizi için Kullanılan Veri Setinin Duygu Dağılımı Grafiği	48
Şekil 5.23 Duygu Analizi için Kullanılan Veri Setinin Duygulara Göre Ortalama Popülerlik Skorları Grafiği	48
Şekil 5.24 Duygu Analizi için Kullanılan Veri Setinin Duygulara Göre Popülerlik Dağılımı Grafiği	49
Şekil 5.25 Duygu Analizi için Kullanılan Veri Setinin Türlere Göre Duygu Dağılımı Grafiği	49
Şekil 5.26 Duygu Analizi için Kullanılan Veri Setinin Tür ve Duygulara Göre Ortalama Popülerlik Skorları Dağılımı Grafiği	50
Şekil 5.27 Duygu Analizi için Kullanılan Veri Setinin Yıllara Göre Ortalama Popülerlik Trendleri Grafiği	51

TABLO LİSTESİ

Tablo 3.1	Kişisel Bilgisayar Donanım Özellikleri	12
Tablo 3.2	Ekonomik Fizibilite Tablosu	13
Tablo 4.1	Hazır Veri Kümesinin Sütunları	15
Tablo 4.2	Hazır Veri Kümesinin Duygulara Göre Örnek Sayısı	16
Tablo 4.3	Dataset 1 Veri Kümesinin Duygulara Göre Örnek Sayısı	17
Tablo 4.4	Dataset 2 Veri Kümesinin Duygulara Göre Örnek Sayısı	17
Tablo 4.5	Dataset 3 Veri Kümesinin Duygulara Göre Örnek Sayısı	18
Tablo 4.6	Duygu Analizi için Kullanılan Veri Kümesinin Sütunları	19
Tablo 4.7	Duygu Analizi için Kullanılan Veri Kümesinin Türlerine Göre Örnek Sayısı	20
Tablo 4.8	Kullanılan Modellerin Karşılaştırılma Tablosu	28
Tablo 5.1	BERT Modeli Parametreleri	30
Tablo 5.2	RoBERTa Modeli Parametreleri	34
Tablo 5.3	DeBERTaV3 Modeli Parametreleri	38
Tablo 5.4	Modellere Göre Özet Performans Karşılaştırması	42
Tablo 5.5	Duygu Analizi için Kullanılan Veri Setinin Türlerine Göre Duygu Dağılımı Tablosu	50
Tablo 5.6	Duygu Analizi için Kullanılan Veri Setinin Tür ve Duygulara Göre Ortalama Popülerlik Skorlarının Yüzdelik Dağılımı Tablosu . . .	51

ŞARKI SÖZLERİNDEKİ DUYGULARIN TÜR VE POPÜLERLİK İLE İLİŞKİSİ

Melih YELMAN

Tarık TAŞKIN

Bilgisayar Mühendisliği Bölümü

Bilgisayar Projesi

Danışman: Öğr. Gör. Dr. Ayşe Öcal

Müzik, tarih boyunca insanların duygularını ifade etmesinde en etkili yollardan biri olmuştur. Müzikte bulunan melodi ve ritim kadar şarkı sözleri de bu duygusal ifadenin önemli bir parçasıdır. Bu çalışmada şarkı sözlerinde ifade edilen duyguların müzik türleri ve popülerlik ile ilişkisi incelenmiştir. Araştırmanın temel motivasyonu, müziğin duygusal etkisinin dinleyici ve endüstriyel başarı üzerindeki rolünü sayısal verilerle ortaya koymaktır.

Çalışma kapsamında, Paul Ekman'ın altı temel duygu modelinde yer alan öfke, iğrenme, korku, neşe, üzüntü ve şaşkınlık duyguları temel alınarak bir sınıflandırma sistemi geliştirilmiştir. Bu sistemi oluşturmak için belirtilen duygularla etiketlenmiş bir veri seti veri ön işleme adımlarından geçirilmiş, ardından sınıf dengesizliğini gidermek için veri artırımı ve veri sınırlama gibi stratejiler kullanılarak çeşitli varyasyonları elde edilmiştir. Bu veri setleri ile BERT, RoBERTa ve DeBERTaV3 modelleri eğitilip performansları karşılaştırılmıştır. Karşılaştırma sonunda en başarılı model %84 doğruluk ve %85 makro F1 skoru ile, kısmi veri artırımı ve sınırlamayla oluşturulan veri setiyle eğitilen RoBERTa modeli olmuştur. Spotify API ve Genius API ile oluşturulan gerçek dünya verisi, bu modelle etiketlenerek istatistiksel analizlere tabi tutulmuştur. Bu analizler sonucunda oluşturulan veri setindeki şarkılarda korku, üzüntü gibi olumsuz duyguların baskın olduğu, bu duyguların popülerlik ile pozitif ilişkili olduğu ve özellikle R&B ile Blues türlerinde duygusal yoğunluk ve popülerliğin yüksek olduğu gözlemlenmiştir.

Bu alıřma ile řarkı szlerindeki ifadelerin duygusal analizi yapılmıř, duygu-tr-poplerlik ls multidisipliner bir yaklařımla ele alınmıřtır. alıřma sonucunda elde edilen bulgular, mzik endstrisi ve akademik alıřmalar iin yol gsterici nitelik tařımaktadır.

Anahtar Kelimeler: BERT, DeBERTaV3, Derin ğrenme, Doęal Dil İřleme, Duygu Analizi, Mzik Tr, Poplerlik, RoBERTa, řarkı Sz

ABSTRACT

THE RELATIONSHIP BETWEEN EMOTIONS IN SONG LYRICS AND GENRE & POPULARITY

Melih YELMAN

Tarık TAŞKIN

Department of Computer Engineering

Computer Project

Advisor: Lect. Dr. Ayşe Öcal

Music has been one of the most effective ways for humans to express their emotions throughout history. In addition to melody and rhythm, lyrics are also a significant component of this emotional expression in music. In this study, the relationship between the emotions expressed in song lyrics and musical genres as well as popularity is examined. The primary motivation of the research is to reveal the role of music's emotional impact on listeners and industrial success using quantitative data.

Within the scope of the study, a classification system was developed based on Paul Ekman's six basic emotion model, which includes anger, disgust, fear, joy, sadness, and surprise. To build this system, a dataset labeled with these emotions was subjected to data preprocessing steps, and then various variations were created by applying strategies such as data augmentation and data limitation to address class imbalance. BERT, RoBERTa, and DeBERTaV3 models were trained using these datasets, and their performances were compared. As a result of the comparison, the most successful model was the RoBERTa model trained with a dataset created through partial augmentation and limitation, achieving %84 accuracy and %85 macro F1 score. Real-world data gathered through the Spotify API and Genius API was labeled using this model and subjected to statistical analyses. The analyses showed that negative emotions such as fear and sadness were dominant in the songs in the dataset, that these emotions were positively correlated with popularity, and that emotional intensity and popularity were especially high in the R&B and Blues genres.

Through this study, an emotional analysis of the expressions in song lyrics was conducted, and the emotion-genre-popularity triad was addressed using a multidisciplinary approach. The findings obtained from the study are of guiding value for both the music industry and academic research.

Keywords: BERT, DeBERTaV3, Deep Learning, Natural Language Processing, Sentiment Analysis, Music Genre, Popularity, RoBERTa, Song Lyrics

Bu bölümde, şarkı sözlerinden duygu analizi projesi hakkında genel bilgiler verilecektir. Öncelikle doğal dil işlemenin temel kavramları ve uygulama alanları ele alınacak, ardından projenin amacı açıklanacaktır.

1.1 Genel Bakış

Doğal dil işleme (NLP), yapay zeka (AI) ve makine öğrenmesi (ML) teknolojilerinin gelişmesiyle birlikte, birçok alanda önemli bir rol oynamaktadır. Metinlerin sınıflandırılması, duyguların analiz edilmesi ve dil tabanlı etkileşimlerin modellenmesi gibi görevler, hem akademik çalışmalarda hem de endüstride yaygın olarak kullanılmaktadır. Özellikle sosyal medya analizleri, müşteri geri bildirimleri, haber metinleri ve çeşitli metin içeriklerinin sınıflandırılması gibi alanlarda doğal dil işlemenin sunduğu olanaklar giderek artmaktadır.

Müzik, tarih boyunca insanların duygularını ifade etmek, paylaşmak ve anlamlandırmak için kullandıkları en güçlü araçlardan biri olmuştur. Sözlü müzik eserlerinde, duygular yalnızca melodi ve ritimle değil, aynı zamanda şarkı sözleri aracılığıyla da aktarılmaktadır. Duyguların şarkı sözleriyle nasıl ifade edildiğini incelemek, müziğin insan üzerindeki etkisini anlamak açısından büyük bir öneme sahiptir. Son yıllarda, müzik ve duygu ilişkisini inceleyen çalışmalar artış göstermekte, bu bağlamda doğal dil işleme teknikleriyle şarkı sözlerinin analizi üzerine yeni yaklaşımlar geliştirilmektedir.

Bu proje kapsamında, şarkı sözlerinde yer alan duyguların belirlenmesi ve analiz edilmesi amaçlanmaktadır. Duygu analizi ile elde edilen veriler, müzik türleri ve popülerite gibi faktörlerle ilişkilendirilerek kapsamlı bir değerlendirme yapılması öngörülmektedir. Proje, müzik ve duygu ilişkisini doğal dil işleme yöntemleriyle inceleyerek, bu alandaki mevcut literatüre katkıda bulunmayı hedeflemektedir.

1.2 Doğal Dil İşleme Nedir?

Doğal dil işleme, makinelerin insan dilini anlama, yorumlama, öğrenme ve üretme yeteneklerini geliştiren çok disiplinli bir alandır. Bu alan, bilgisayar bilimi ve yapay zekayı bir araya getirip İngilizce, Türkçe, Fransızca ve birçok dili kapsayacak şekilde metinleri analiz ederek bilgi çıkarımı yapar. Ancak, insan dili doğası gereği düzensiz olduğu için sürekli olarak değişime uğramaktadır. Bu nedenle, doğal dil işleme teknolojisinin temel hedefi, makinelerin dilin karmaşık yapısını kavrayıp insanlar gibi doğal dili anlamlandırmasını sağlamaktır.

Doğal dil işlemenin temelleri, 20. yüzyılın ortalarında bilgisayarların geliştirilmesiyle başlayan araştırmalara kadar uzanmaktadır. Son yıllarda makine öğrenmesinin alt dalı olan derin öğrenme (DL) yöntemlerindeki gelişmeler sayesinde, dillerin yapısını tanıyıp taklit edebilen sistemler geliştirilebilmiştir. Bilgisayarların insan dilini anlama, yorumlama ve üretme kapasitesindeki ilerlemeler, insanlarla daha doğal ve etkili etkileşimler kurabilmek açısından büyük önem taşımaktadır. Bu nedenle, NLP yalnızca bir teknolojik gelişme değil, aynı zamanda geleceğin bilgisayar sistemlerinde kritik bir bileşen olarak öne çıkmaktadır [1].

Doğal dil işleme alanındaki kritik zorluklardan biri, doğal dil üretimi (NLG) ve doğal dil anlama (NLU) olmak üzere iki temel alt alanda araştırma yapmaktır. Doğal dil anlama, metinlerde bulunan duyguları, varlıkları, kavramları ve anahtar kelimeleri inceleyerek bilgisayarların dili yorumlamasını sağlayan bir yöntemdir. Buna karşılık, doğal dil üretimi, makinelerin iç temsillerden türetilen bağdaşık ifadeler ve paragraflar üretmesini sağlayan bir yöntemdir. Hedeflerin belirlenmesi, stratejik faaliyetlerin formüle edilmesi ve metin üretimi bu süreçlerin kritik unsurlarıdır [1].

Doğal dil işleme teknolojileri günlük hayatta uygulanabilmektedir. Örneğin, Siri ve Amazon Alexa gibi akıllı cihazlardaki sohbet robotları ve sanal asistanlar bu teknolojiyi sürekli olarak kullanmaktadır. NLP uygulamaları duygu analizi, e-posta spam filtreleri ve arama motoru sorgulamalarını kapsamaktadır.

1.3 Doğal Dil İşleme Uygulama Alanları

Doğal dil işleme, dilin işlenmesi ve analiz edilmesi için birçok uygulama alanında kullanılmaktadır. Bu alanlar, dilin çeşitli yönlerini anlamak ve uygulamalı çözümler üretmek amacıyla ortaya çıkmıştır. Makine çevirisi, metinleri bir dilden başka bir dile çevrilmesini sağlarken, metin sınıflandırma, içerikleri belirli kategorilere ayrılmasında rol oynar. Spam filtreleme, istenmeyen içeriklerin belirlerken, duygu analizi ise metinlerdeki duygusal eğilimleri belirler. Bu uygulama alanları, doğal dil işlemeyi

çeşitli sektörlerde ve günlük hayatta kullanabilme imkanı sunmaktadır.

Makine çevirisi, doğal dil işleme uygulamalarının en eski uygulama alanlarından birisidir. Bu teknoloji, metinleri ve konuşmaları anlam bütünlüğünü bozmadan, bir dilden diğer bir dile çevirmeyi amaçlar. Özellikle derin öğrenme ve sinir ağları alanındaki gelişmeler, makine çevirisinin kalitesini önemli ölçüde artırmıştır. Örneğin, Google, 2016 yılında derin öğrenme tabanlı bir çeviri sistemini tanıtarak diller arası çeviri kalitesini büyük ölçüde geliştirmiştir. Bu teknoloji, kullanıcılara dilsel ve kültürel engelleri aşmada yardımcı olmaktadır. Ancak, dilbilgisi hataları ve kültürel farklılıklar gibi engellerle karşılaşmaya devam etmektedir.

Metin sınıflandırma, metinleri içeriklerine göre belirli kategorilere ayırmayı amaçlayan bir doğal dil işleme alanıdır. Haber makalelerinin konularına göre sınıflandırılması veya müşteri yorumlarının olumlu ya da olumsuz olarak etiketlenmesi gibi uygulamalar, bu alanın en yaygın kullanım örneklerindendir. Geleneksel olarak Naïve Bayes ve destek vektör makineleri (SVM) gibi makine öğrenmesi algoritmaları kullanılırken, günümüzde daha yüksek doğruluk oranlarına ulaşan BERT (Bidirectional Encoder Representations from Transformers) gibi derin öğrenme modelleri öne çıkmaktadır [2].

Spam filtreleme, metinlerin kelime kalıpları, frekansları ve bağlamsal analizleri gerçekleştirerek spam olup olmadığını belirleyen doğal dil işleme alanıdır. Bu amaçla yaygın olarak kullanılan bir yöntem olan Naïve Bayes sınıflandırıcısı, e-postadaki kelimelerin spam olarak değerlendirilme olasılığını hesaplayarak e-postanın spam olup olmadığına karar verir. Gelişmiş spam filtreleme sistemleri ise sadece kelime frekanslarını incelemekle kalmaz, aynı zamanda e-posta içeriğini, gönderen bilgilerini ve bağlantıları da analiz ederek daha kapsamlı bir değerlendirme yapar. Ayrıca Latent Dirichlet Allocation gibi konu modelleme teknikleri de içerik bazlı analizler ile bir e-postanın spam olup olmadığını belirlemede kullanılmaktadır. Spam filtreleme yöntemleri sadece e-posta hizmetlerinde değil, aynı zamanda sosyal medya platformları, SMS hizmetleri ve anlık mesajlaşma uygulamalarında da sıklıkla kullanılmaktadır [3].

Duygu analizi, metinlerdeki duygusal ifadeleri belirlemek ve bu ifadeleri sınıflandırmak için kullanılan bir doğal dil işleme yöntemidir. Bu teknik, özellikle müşteri geri bildirimleri, sosyal medya paylaşımları ve ürün incelemeleri gibi çeşitli alanlarda metinlerden kullanıcı duyarlılıklarını ve eğilimlerini analiz etmek için yaygın olarak uygulanmaktadır. Duygu analizi, genellikle metinleri olumlu, olumsuz veya nötr olarak sınıflandırsa da, daha ayrıntılı analizlerde sevinç, öfke, üzüntü gibi çok duygulu kategoriler de belirlenebilmektedir. Geleneksel olarak, duygu

analizi için Naïve Bayes, SVM ve lojistik regresyon gibi makine öğrenmesi yöntemleri kullanılmaktadır. Ancak, son yıllarda BERT, LSTM (Long Short-Term Memory) gibi derin öğrenme modelleri metinlerdeki bağlamı daha iyi değerlendirerek bu alanda daha başarılı sonuçlar elde etmektedir.

1.4 Projenin Amacı

Tarih boyunca sanatçılar, müziğe çeşitli iletişimsel ve duygusal roller yüklemiştir. Bazı sanatçılar zaman zaman müziği acılarını anlatmak, bazı sanatçılar insanları eğlendirmek, bazı sanatçılar toplumsal dönüşümü tetiklemek ve bazı sanatçılar ise müziği ruhu dinlendirmek için kullanmışlardır. Bu tarihsel miras, müzik ile duygusal deneyim arasındaki etkileşimin yalnızca bugüne özel bir olay olmadığını, insanlık tarihi boyunca kalıcı bir özelliği olduğunu göstermektedir.

Günümüzde insanlar, müziği çeşitli duygularını beslemek, ifade etmek ve bastırmakta kullanmaktadır. Şarkı sözleri, insan ruhunu beslemekte ve çeşitli duygusal etkiler yansıtmakta olduğundan insanlar şarkılardan etkilenmektedir. Ayrıca, toplumda baskın olarak dinlenen şarkılar dolaylı yollardan bireyi etkilemektedir. Sonuç olarak, şarkı sözlerinden oluşan duygular önemli ölçüde müzik türlerinden ve müzik popülaritesinden etkilenmektedir.

Müzik ve duygu arasındaki ilişkiyi kavrayabilmek, müzik, psikoloji ve doğal dil işleme gibi disiplinleri birleştiren yeni multidisipliner araştırma ortamı yaratmaktadır. Şarkı sözlerindeki duyguların tür ve popülerlik ile ilişkisi, müzik endüstrisinin bir şarkının duygusal rezonansını nasıl etkilediğini belirlemelerine destek sağlamaktadır. Bununla birlikte müzik endüstrisinin müzik üretim ve pazarlama planlarına destek sağlamaktadır.

Bu çalışma, şarkı sözlerindeki duygusal etkileri saptamayı ve bu duygular ile müzik türleri ve popülerite arasındaki ilişkiyi incelemeyi amaçlamaktadır. Şarkı sözlerinin duygusal analizi, doğal dil işleme teknikleri kullanılarak dinleyicilerin etkilendiği duyguların yoğunluğunu tespit etmeyi amaçlamaktadır. Amaç, şarkıların duygusal içeriği, türleri ve popülerite skorları arasındaki ilişkileri detaylı biçimde analiz ederek, müzik endüstrisine, müzisyenlere ve akademisyenlere detaylı bilgiler sunmaktır.


2 LİTERATÜR ANALİZİ

Bu bölümde, şarkı sözlerinden duygu analizi kapsamında daha önceden yapılmış araştırmalara ve bu araştırmaların ortaya koyduğu sonuçlara yer verilecektir. Literatürde bulunan yaklaşımlar, kullanılan metodlar ve edinilen veriler temel alınarak, araştırmamız kapsamında yapılacak olan duygu analizinin yeri ve katkısı tartışılacaktır. Ayrıca, yapılan bu çalışmaların kısıtlamaları ile geliştirilebilecek yönler değerlendirilerek, projemizde yapılacak yöntemlerin literatüre katacağı yenilikler ele alınacaktır.

2.1 Geçmiş Yaklaşımlar

Müzik ve duygu analizi, şarkı sözleri ve akustik özelliklerin duygusal içeriklerini sınıflandırmak amacıyla birçok farklı makine öğrenmesi ve derin öğrenme yönteminin kullanıldığı bir araştırma alanıdır. Bu çalışmalar, duyguların daha ayrıntılı kategorilerle etiketlenmesi ve müzikle ilişkili duygusal içeriklerin daha doğru bir şekilde belirlenmesi hedeflenmektedir.

Müzik ve duygu ilişkisini anlamaya yönelik çalışmaların çoğunluğunda, müzik parçalarının yalnızca pozitif veya negatif olarak sınıflandırılmasına odaklanılmıştır. Ancak araştırmacılar, şarkı sözlerinin Plutchik'in duygu çarkındaki sekiz temel duygu üzerinden etiketlenebileceği gösterilmiştir [4]. Çalışmada Naive Bayes, Random Forest ve BERT gibi yöntemler kullanılmış, özellikle küçük bir şarkı veri setiyle BERT modelinin performansının önemli ölçüde arttığı belirtilmiştir [5].



Şekil 2.1 Plutchik'in Duygu Çarkıfeleği

Başka bir çalışmada, makine öğrenme modellerinde kullanılmak üzere müzik duygu tanıma (MER) alanında veri seti oluşturulmuş. AllMusic, Last.fm ve Twitter gibi sitelerden toplanan verilerle 508.872 şarkı ve 546 duygu etiketinden oluşan bir veri seti oluşturulmuştur. YAMNet modelini temel alan transfer öğrenme metodu kullanılarak, %59 ile %83 arasında duygu analizi doğruluğuna ulaşılmıştır. MER araştırmalarında, veri setinin toplandığı şarkıların kültürel özelliklerinden dolayı ortaya çıkan önyargıların azaltılması yoluyla müzikal etkilerin daha açık kavranmasını hedefleyecek açıklanabilir yapay zeka metodlarını kullanmanın öneminden bahsedilmiştir [6].

Başka bir çalışmada, şarkı sözlerinin duygu durumu üzerindeki etkisi araştırılmış ve XLNet'i temel alan bir transformer metodu uygulanmıştır. MoodLyrics [7], MER ve AllMusic veri setleri kullanılan araştırmada, özellikle AllMusic veri setinde, %76,31 doğruluk ve %75,40 F1 skoru sonuçları tekli sınıflandırma için elde edilmiştir. Çoklu sınıflandırma yapısı üretilen modelin daha hızlı tahmin etmesini sağlasa da, tekli sınıflandırma yapısının sonuçları daha başarılı olmuştur. Araştırma, duyguyu temel alan çalma listeleri oluşturma ve müzik öneri sistemlerinde, şarkı sözlerinin duygusal özelliğini kullanarak doğruluğu yükseltmek bakımından katkı sunmaktadır [8].

Başka bir çalışmada, şarkı sözlerinden duygu analizi için regresyon kullanılmış ve her bir şarkı için arousal ve valence değerleri tahmin edilerek örnekler duygusal bir sınıflandırma yapılmıştır. Regresyon kullanılarak elde edilen sonuçlar için arousal %58.3, valence ise %28.1 doğruluk elde edilmiştir. Arousal ve valence arasındaki korelasyon temel bileşen analizi ile azaltılarak doğruluk artırılmıştır. Bu araştırma, şarkı sözleri ve şarkı söyleme gibi ek özelliklerin kullanımının yanında daha büyük veri setleriyle araştırılma yapılmasını önermektedir [9].

Başka bir çalışmada, müziğin duygusal analizi aşamasında şarkı sözlerinin önemi incelenmiş; stilistik, yapısal ve semantik özelliklerin kombinasyonuna dayanan bir yaklaşım önerilmiştir. 180 şarkı sözünden oluşan veri setiyle yapılan 4 deneyde (regresyon, quadrant, valence ve arousal sınıflandırılması) modelin, mevcut tekniklere göre sınıflandırma tahmini önemli bir ölçüde arttırdığı gözlemlenmiştir. Eklenen özelliklerle kadran için F skoru %69,9'dan %80,1'e, arousal için %82,7'den %88,3'e ve valence için %85,6'dan %90'a çıkmıştır. Araştırma, şarkı sözlerinin müziğin duygusal analizi sürecinde daha fazla kullanılmasını hedeflemektedir [10].

Başka bir çalışmada, diğer çalışmalarda olduğu gibi şarkı sözlerinden duygu analizi yapmak için makine öğrenmesi tekniklerinin kullanılmasının yerine otomatik sınıflandırma yöntemi kullanılmıştır. Geliştirilen model, 23 farklı duyguyu kapsayacak biçimde arttırılmış ve bu modelle binlerce şarkının sınıflandırıldığından bahsedilmiştir. Araştırmada, şarkı sözleri içerik analizi metoduyla 182 psikolojik özellikten oluşan bir özellik vektörüne çevrilmiş ve karar ağacı yöntemiyle duygu sınıflandırma modeli geliştirilmiştir. Sonuçlar, insan tarafından anlaşılabilir olduğu ve içgüdüyle temel alan beklentilerle kesiştiği söylenmiştir. Ayrıca, daha kesin duygu sınıflandırma modelleri için akustik ve şarkı sözü temel alan modeller geliştirilmesi öne sürülmüştür [11].

Başka bir çalışmada, şarkı sözlerinden duygu analizi için Bi-LSTM derin öğrenme tekniğini kullanarak, üç farklı kelime gömme modeli olarak Word2Vec, GloVe ve FastText kullanılmış, sonuçları incelenmiştir. MoodyLyrics [7] ve Music Lyrics Kaggle veri setleri kullanılan analizlerde, MoodyLyrics en yüksek doğruluk %64, Music Lyrics Kaggle veri seti ise %42 doğruluk sonucu vermiştir. GloVe modelinin, 300 boyutlu kelime vektörleri, 0.1 öğrenme oranı, 40 kelime gömme epoch'u ve 60 Bi-LSTM epoch'u ile birlikte en optimum sonuç veren model olduğu saptanmıştır [12].

Başka bir çalışmada, şarkı sözlerinden duygu analizi için derin öğrenme modelleri kullanılmış ve tekil ile füzyon modellerinin sonuçları karşılaştırılmıştır. Analizlerde, müzik verisinin arousal boyutuyla, şarkı sözlerinin ise valence ayrımının önemli bir nokta olduğu belirlenmiştir. Füzyon modeli, müzik ve şarkı sözünü eş zamanlı kullanarak tekil modele kıyasla daha performanslı olduğu gözlemlenmiştir. Ayrıca,

arousal ve valence tahminlerinin ayrı yapılması, dört duygusal çeyrek bazlı tahminlere kıyasla daha doğru sonuç verdiği belirlenmiştir. Arousal ve valence tahmininde %79,91 doğruluk, dört çeyrek bazlı tahminde ise %68,75 doğruluk elde edilmiştir. PME veri seti kullanılarak yapılan analizlerde %13-%16 arasında bir artış olduğu gözlemlenmiştir [13].

Başka bir çalışmada, şarkının popülerliğini belirleyen faktörlerden birinin şarkı sözlerindeki duyguların olduğu tespit edilmiş ve buna dayanarak duygu tahmini yapabilen bir model oluşturulmuştur. SpotGenTrack [14] veri seti kullanılarak BERT modeli fine-tune edilmiştir. Veri setinde bulunan 52.278 şarkı ile yapılan çalışmada, %88 kesinlik, %87 duyarlılık, doğruluk ve F1 skoru sonuçları elde edilmiştir. Bu sonuçlar, BERT modeli kullanılarak ve %73 doğruluk skoru elde edilen önceki bir çalışmaya göre daha yüksek bulunmuştur [15].

Sonuç olarak, şarkı sözleri üzerinden duygu analizi konusunda yapılan çalışmalar, farklı metodolojik yaklaşımlar ve veri işleme teknikleri açısından çeşitlilik göstermektedir. Makine öğrenmesi, derin öğrenme ve transformer tabanlı modellerin kullanıldığı araştırmalar, bu alandaki ilerlemeyi ortaya koymaktadır. Bununla birlikte, veri setlerindeki dengesizlikler, çok modlu veri kullanımının gerekliliği ve belirli duygu kategorilerinde düşük performans gibi sorunlar, ilerleyen çalışmalar için ele alınması gereken önemli noktalar arasında yer almaktadır.

2.2 Çıkarımlar

Literatür analizinin yapılması sonucunda elde edilen çıkarımlar, şarkı sözlerinin duygusal içeriklerinin doğru bir şekilde sınıflandırılması için çoğunlukla makine öğrenmesi ve derin öğrenme yöntemlerinin kullanıldığı gözlemlenilmiştir. Bu alanda yapılan çalışmalar, Plutchik'in duygu çarkı gibi duygu sınıflandırma modellerinin kullanılmasıyla birlikte şarkı sözleri ile duygu arasındaki ilişkiyi detaylandırarak elde edilen başarının artırabileceğini göstermektedir. Şarkı sözü ile ilişkili duygu tahminlerinin doğruluğu, BERT gibi sağlam derin öğrenme modellerinin küçük veri setlerinde bile yüksek performanslı bir şekilde kullanılarak büyük bir oranda artırılabilmesi ortaya konulmuştur. Ayrıca, daha geniş duygusal çeşitliliği ve çok modlu veri ve müziğin de modelin daha kapsamlı bir şekilde çalışmasını ve daha doğru sonuçlar üretmesini sağlayabileceği görülmüştür.

Elde edilen bir diğer önemli çıkarım ise, şarkı sözleri ile birlikte müziğin de incelenmesi duygu analizi başarısını fark edilir bir şekilde artırdığıdır. Çalışmalar, duygu tahminlerinde sadece şarkı sözlerinin kullanıldığı geleneksel yöntemlerin yetersiz kaldığını ve buna ek olarak müziğin de dikkate alındığı çok modlu duygu

modellerinin daha iyi sonuçlar elde ettiğini göstermektedir. Bununla birlikte, şarkı sözleri üzerinde yapılan duygu sınıflandırmalarının popülarlık ve tür gibi faktörler ile ilişkisinin incelendiği çalışmalarda, bu alanın daha da derinleştirilmesi gerektiğini vurgulamaktadır. Veri dengesizlikleri, sınıflandırma hataları gibi engellere rağmen ilerleyen çalışmalarda bu sorunlara çözüm getirecek yenilikçi çözümler için çalışılması gerektiğinin altı çizilmiştir.

Bu proje ile, literatürdeki mevcut yaklaşımlardaki gibi şarkı sözleri üzerinden duygu analizi yapılmasını hedeflemektedir. BERT modeli, şarkı sözlerinden duyguları analiz etmek için fine-tune edilerek kullanılacak, elde edilen duygular tür ve popülarlık gibi faktörlerle ilişkilendirilerek daha derin bir analiz gerçekleştirilecektir. Bu şekilde, şarkı sözlerinin duygusal içeriği ile şarkı türleri ve popülarlık arasındaki potansiyel bağlantılar incelenmeye çalışılacaktır. Bu yaklaşım, duygu analizi ve şarkı ilişkisini farklı bir perspektiften ele almayı mümkün kılmaktadır.

3 SİSTEM ANALİZİ ve FİZİBİLİTE

Bu bölümde, projenin gereksinimlerinin kapsamlı bir şekilde analiz edilmesi ve en uygun çözüm yollarının belirlenmesi amacıyla sistem analizi gerçekleştirilecektir. Sistem analizi sürecinde, projenin hedefleri, bilgi kaynakları ve teknik ihtiyaçları detaylandırılacak, tasarım aşamasına geçişi kolaylaştıracak sağlam bir temel oluşturulacaktır.

3.1 Sistem Analizi

Bu bölümde, projenin en uygun şekilde hayata geçirilmesi için temel bileşenler ve işlevler belirlenerek analiz edilecektir. Projenin temel hedefleri detaylandırılacak, bilgi kaynakları ve teknik gereksinimler tanımlanacaktır. Sistem analizi sonucunda, tasarım aşamasına geçişi sağlayacak en uygun çözüm belirlenerek, proje tamamlandığında ihtiyaçların karşılanıp karşılanmadığını değerlendirecek bir yapı ortaya konulacaktır.

3.1.1 Projenin Hedefleri

Projenin temel amacı, şarkı sözleri üzerinden duygu analizi yapılarak müziğin duygusal etkisinin incelenmesidir. BERT tabanlı bir model eğitilerek şarkı sözleri, altı temel duygu (korku, üzüntü, öfke, sevinç, şaşkınlık ve iğrenme) sınıfı ile çoklu etiketleme yöntemi kullanılarak analizin gerçekleştirilmesi hedeflenmektedir. Proje sonucunda, şarkı türü-duygu ilişkisi ve duygu-popülerlik ilişkileri incelenip görselleştirilerek kullanıcıya sunulacaktır. Böylece müzik endüstrisinde ve kişisel müzik deneyiminde kullanılabilecek bir duygu analizi sisteminin geliştirilmesi amaçlanmaktadır.

3.1.2 Bilgi Kaynakları ve Gereksinimler

Model eğitimi için gerekli olan şarkı sözleri üzerinde etiketlenmiş duygu bilgilerini içeren veri setleri, açık kaynaklı ve ücretsiz olan Kaggle ve Hugging Face platformlarından sağlanacaktır. Veri ön işleme ve model eğitimi için Python programlama dili tercih edilip, TensorFlow ve Hugging Face Transformers kütüphaneleri model geliştirme sürecinde temel bileşenler olarak kullanılacaktır. Proje geliştirme ortamı olarak Visual Studio Code ve Jupyter Notebook kullanılacaktır. Bununla birlikte, model eğitimi için yüksek işlem gücüne sahip bir GPU gerekmekte olup, bu ihtiyacı karşılamak için Google Colab Pro hizmetinden yararlanılacaktır.

3.1.3 Performans Metrikleri ve Başarı Kriterleri

Modelin duygu analizi performansını değerlendirmek için doğruluk (accuracy), kesinlik (precision), duyarlılık (recall) ve F1 skoru gibi temel performans metrikleri kullanılacaktır. Bu metrikler, modelin sınıflandırma doğruluğunu ve dengesini ölçerek, her bir duygu kategorisini ne kadar iyi tespit edebildiğini matematiksel olarak ortaya koyacaktır. Ayrıca, modelin başarısını artırmak ve genel performansını daha güvenilir hale getirmek amacıyla çapraz doğrulama (cross-validation) yöntemi uygulanacaktır. Bu sayede modelin aşırı öğrenme (overfitting) yapması önlenerek gerçek dünya verileri üzerinde daha iyi genelleme yapabilmesi sağlanacaktır. Bununla birlikte, modelin eğitimi sırasında işlem süresi ve tahmin yapma hızı da göz önünde bulundurularak, hem doğruluk hem de verimlilik açısından dengeli bir yapı oluşturulacaktır. Belirlenen bu kriterler, modelin değerlendirilmesi ve projenin başarıya ulaşması için temel kriterleri oluşturacaktır.

3.2 Fizibilite

Bu bölümde, projenin uygulanabilirliğini değerlendirmek amacıyla teknik, yasal, ekonomik ve zaman fizibilitesinden bahsedilecektir.

3.2.1 Teknik Fizibilite

Projenin teknik olarak uygulanabilirliği bu bölümde değerlendirilip ihtiyaç duyulan yazılım ve donanım gereksinimlerinden bahsedilecek, sistemin verimli bir şekilde çalışması için kullanılacak olan teknolojiler incelenecektir.

3.2.1.1 Yazılım Fizibilitesi

Proje kapsamında kullanılacak olan yazılımlar belirlenmiş, açık kaynak kodlu kütüphanelerin tercih edilmesi geliştirme sürecini kolaylaştırmıştır. Doğal dil işleme, derin öğrenme gibi yapay zeka kütüphanelerini barındırmasından, projenin gerçekleştirileceği işletim sistemleri olan Windows 11 ve MacOS ile erişilebilirliğinden ve kullanım kolaylığından dolayı projenin, Python (3.12 ve üzeri) ile geliştirilmesine karar verilmiştir. Ayrıca sahip olduğu veri görselleştirme kütüphaneleri ve Jupyter Notebook ile uyumu da projenin hızlı ve doğru bir şekilde gerçekleştirilmesine büyük bir derecede katkı sağlayacaktır.

3.2.1.2 Donanım Fizibilitesi

Projede en çok sistem gereksinimi gerektiren uygulama model eğitimidir. Model eğitimi, yüksek sistem gereksinimleri gerektirdiğinden dolayı güçlü donanımların kullanılması önemli ölçüde zaman kazandıracaktır. Özellikle derin öğrenme tabanlı doğal dil işleme modelleri, büyük veri kümeleri ile işlem yaparken yoğun hesaplama gerektirir ve sistem kullanımı hat safhalarda olur. Bu yüzden, GPU desteği bulunan sistemlerin kullanımı hesaplama sürelerini büyük bir ölçüde azaltarak modellerin daha hızlı eğitilmesine yardımcı olur. GPU kullanımının mümkün olmadığı durumdaysa model, CPU tarafından eğitilir ancak bu, GPU kadar verimli olmayan bir süreçtir. Proje geliştirmesinde kullanılacak olan sistemlerin GPU desteği yeterli olmadığından dolayı Google Colab gibi bulut tabanlı, çevrimiçi hizmetler kullanılarak yüksek işlem gücüne sahip donanımlardan faydalanılacaktır. Ayrıca, projenin ekip çalışması gerektirdiğinden dolayı kodların senkronize bir şekilde geliştirilmesi, paylaşılması ve sürüm kontrolünün sağlanması için bulut tabanlı sistemlerden faydalanılacaktır. Böylece, ekip üyeleri projeyi eş zamanlı ve iş birliği içinde etkin bir şekilde gerçekleştirebilecektir.

Tablo 3.1 Kişisel Bilgisayar Donanım Özellikleri

Özellik	Melih Yelman'ın Bilgisayarı	Tarık Taşkın'ın Bilgisayarı
Marka ve Model	Apple Macbook Air M3 2022	HUAWEI Matebook 14 2022
İşlemci	Apple M2	Intel Core i5-1240P
Ekran Kartı	M2	Intel Iris Xe Graphics
RAM	16 GB	16 GB
Depolama	512 GB	512 GB
İşletim Sistemi	MacOS	Windows 11

3.2.2 Yasal Fizibilite

Projede kullanılacak olan veri setleri, açık kaynak lisansları kapsamında ücretsiz olarak sunulan Kaggle ve Hugging Face platformlarından temin edilecektir. Bu nedenle, veri setlerinin kullanımı herhangi bir yasal sorumluluk teşkil etmemekte ve lisans koşullarına uygun bir şekilde projeye entegre edilmektedir.

Ayrıca, proje kapsamında herhangi bir kişisel veri toplanılmamakta ve kullanıcı gizliliğini ihlal eden herhangi bir veri işlenmemektedir. Kullanılacak tüm kütüphaneler, framework'ler ve API'lar açık kaynaklı olup, herhangi bir patent veya telif hakkı ihlali oluşturmamaktadır. Böylece, proje mevcut yasa ve yönetmeliklere aykırı herhangi bir durum barındırmamaktadır.

3.2.3 Ekonomik Fizibilite

Proje geliştirilmesinde kullanılacak olan yazılım araçlarının büyük bir kısmı ücretsiz olduğu için yazılım maliyetleri bakımından ek bir harcama gerekmemektedir. Kod editörü olarak açık kaynak kodlu Visual Studio Code kullanılacak olup, herhangi bir lisans ücreti gerekmemektedir. Benzer şekilde, model eğitimi için kullanılacak olan yapay zeka ve doğal dil işleme kütüphaneleri de ücretsiz bir şekilde kullanılabilir. Ancak model eğitimi için gerekli olan GPU desteği karşılanamadığından, aylık belirli bir ücret karşılığında gelişmiş GPU desteği sunan Google Colab Pro üyeliği satın alınacaktır. Model geliştirme sürecinin verimli gerçekleştirilebilmesi için bu hizmetten üç ay boyunca faydalanılacaktır. Model eğitimi dışında gerçekleştirilecek olan işlemler için ekip üyelerinin kişisel bilgisayarları fazlasıyla yeterli gelmektedir.


Bunun dışında, proje kapsamında kullanılan veri setleri de açık kaynaklı olup, herhangi bir lisans ücreti gerektirmemektedir. Bu doğrultuda, proje için sadece Google Colab Pro üyeliği satın alınacaktır.

Tablo 3.2 Ekonomik Fizibilite Tablosu

Araç	Adet	Fiyat	Maliyet
Apple Macbook Air M2 2023	1	48000 TL	48000 TL
HUAWEI Matebook 14 2022	1	36000 TL	36000 TL
Aylık Google Colab Pro Üyeliği	3	160 TL	480 TL
Toplam Maliyet			84480 TL

3.2.4 İş Gücü ve Zaman Fizibilitesi

Proje, iki kişilik ekip tarafından üç ay süresi içerisinde tamamlanması planlanmış olup belirlenen aşamalar doğrultusunda gerçekleştirilecektir. Belirlenen süre içerisinde her aşamanın zamanında tamamlanması için zaman yönetimi büyük önem taşıdığından, projenin en etkin bir şekilde gerçekleştirilmesi için Şekil 3.1’de belirtilen Gantt diyagramındaki gibi ilerlenilmesi hedeflenmektedir.



Şekil 3.1 Gantt Şeması

4 SİSTEM TASARIMI

Bu bölümde, projenin genel mimarisi ve işleyiş aşamaları açıklanacaktır. İlk olarak, sistem tasarımı kapsamında kullanılan veri kümeleri ve bunların hazırlanma süreci incelenecek, daha sonra modelleme aşamasında uygulanan yöntemler ve seçilen modeller daha ayrıntılı şekilde ele alınacaktır.

4.1 Materyal ve Veri Kümesi

Bu bölümde, model eğitimi ve duygu analizi için kullanılan veri kümeleri tanıtılacaktır. Veri kaynaklarının nasıl toplandığı, içerikleri ve bu verilere uygulanan işlemler alt başlıklar ile açıklanmıştır.

4.1.1 Model Eğitimi İçin Kullanılan Hazır Veri Kümesi

Modelin eğitimi için HuggingFace platformu üzerinden erişilebilen duygu etiketli şarkı sözleri içeren veri kümesi kullanılmıştır [16]. Veri kümesi tamamında 36.897 örnek içermektedir. Ancak bu örneklerin hepsi direkt kullanılmamış, bazı ön işlemler uygulanmıştır. İlk olarak veri kümesinden eksik değer içeren satırlar silinmiş, daha sonra benzer örnekler silinmiştir. Silme işlemlerinden sonra modelin performansını arttıracak şekilde veri kümesine işlemler uygulanmıştır. Bu işlemler, diğer bölümlerde detaylandırılacaktır. Hazır veri kümesinde olan sütunlar Tablo 4.1'deki gibidir.

Tablo 4.1 Hazır Veri Kümesinin Sütunları


Sütun Adı	Açıklama
id	Örneğe ait benzersiz kimlik
artist	Şarkıyı seslendiren sanatçı
seq	Şarkı sözü
song	Şarkı adı
label_name	Etiketli duygu sınıfı

Proje, Paul Ekman'ın 6 temel duygu modeli baz alınarak geliştirildiği için veri kümesinden 'neutral' sınıfı çıkarılmıştır. Veri kümesi ön işleme sonucunda oluşan sınıfların örnek sayıları Tablo 4.2'deki gibidir.

Tablo 4.2 Hazır Veri Kümesinin Duygulara Göre Örnek Sayısı

Duygu Etiketi	anger	disgust	fear	joy	neutral	sadness	surprise
Başlangıç	4.023	831	10.937	2.881	5.719	10.798	1.706
Son Durum	3.342	699	8.324	1.756	0	7.417	1.306

Yapılan işlemlerle birlikte elde edilen veri kümesi dağılımı ise Şekil 4.1'deki pasta grafiği ile görselleştirilmiştir. Grafik üzerinde her bir duygu sınıfının veri kümesindeki oranı açıkça görülmektedir.



Şekil 4.1 Veri İşleme Adımları Sonucunda Elde Edilen Hazır Veri Kümesinin Sınıf Dağılımı

4.1.2 Hazır Veri Kümesi Üzerinde Yapılan İşlemler Sonucunda Oluşan Veri Kümeleri


Hazır veri kümesi üzerinde modellerin daha iyi sonuç verebilmesi için sınıf bazlı daraltma veya veri artırma yani augmentasyon işlemi uygulanmıştır. Bu bölümde, elde edilen yeni veri kümeleri tanıtılacaktır.

4.1.2.1 Sadece Disgust Sınıfına Augmentasyon İşlemi Yapılan Veri Kümesi

Hazır veri kümesindeki 'disgust' sınıfının sayısının çok az olmasından dolayı bir augmentasyon işlemi yapılmıştır. Bundan sonra bu veri kümesi, Dataset 1 olarak adlandırılacaktır. Veri kümesindeki örnek sayıları ve sınıf dağılımları sırasıyla Tablo 4.3 ve Şekil 4.2'de yer verilmiştir.

Tablo 4.3 Dataset 1 Veri Kümesinin Duygulara Göre Örnek Sayısı

Duygu Etiketi	anger	disgust	fear	joy	sadness	surprise
Hazır Veri Kümesi	3.342	699	8.324	1.756	7.417	1.306
Dataset 1	3.341	1.383	8.307	1.743	7.399	1.303




Şekil 4.2 Dataset 1 Veri Kümesinin Sınıf Dağılımı

4.1.2.2 Sınırlanarak ve Arttırılarak Kısmi Denge Sağlanmış Veri Kümesi

Hazır veri kümesindeki yoğun sınıfları 4000 örnekle sınırlandırarak ve diğer sınıfları bu sayıya augmentasyon işlemi yapılarak yaklaştırılmaya çalışılmıştır. Bundan sonra bu veri kümesi, Dataset 2 olarak adlandırılacaktır. Veri kümesindeki örnek sayıları ve sınıf dağılımları sırasıyla Tablo 4.4 ve Şekil 4.3'te yer verilmiştir.

Tablo 4.4 Dataset 2 Veri Kümesinin Duygulara Göre Örnek Sayısı

Duygu Etiketi	anger	disgust	fear	joy	sadness	surprise
Hazır Veri Kümesi	3.342	699	8.324	1.756	7.417	1.306
Dataset 2	4.045	1.913	4.000	3.643	4.000	2.990




Şekil 4.3 Dataset 2 Veri Kümesinin Sınıf Dağılımı

4.1.2.3 Sınırlanarak ve Arttırılarak Tam Denge Sağlanmış Veri Kümesi

Hazır veri kümesindeki sınıfları 2000 örnekle sınırlandırarak ve augmentasyon işlemi yapılarak tam denge sağlanmaya çalışılmıştır. Bundan sonra bu veri kümesi, Dataset 3 olarak adlandırılacaktır. Veri kümesindeki örnek sayıları ve sınıf dağılımları sırasıyla Tablo 4.5 ve Şekil 4.4'te yer verilmiştir.

Tablo 4.5 Dataset 3 Veri Kümesinin Duygulara Göre Örnek Sayısı

Duygu Etiketi	anger	disgust	fear	joy	sadness	surprise
Hazır Veri Kümesi	3.342	699	8.324	1.756	7.417	1.306
Dataset 3	2.000	2.000	2.000	2.000	2.000	2.000



Şekil 4.4 Dataset 3 Veri Kümesinin Sınıf Dağılımı

4.1.3 Duygu Analizi için Kullanılan Veri Kümesi

Duygu tahmin edebilen model eğitimi tamamlandıktan sonra duygu analizine tabi tutulacak şarkılar, Spotify ve Genius API'leri kullanılarak toplanmıştır. Bu çalışmada, 7.219 şarkıdan oluşan bir veri kümesi oluşturulmuştur. Şarkı sözleri Genius API'den, şarkı adı, sanatçı, tür, popülerite, yayın yılı gibi meta veriler ise Spotify API kullanılarak elde edilmiştir. Veri toplamak için filtreleme kriterleri uygulanmıştır. Müzik türleri için pop, rock, hip-hop, r&b, country ve blues seçilmiş, sadece Amerika Birleşik Devletleri pazarında yayınlanan şarkılar seçilmiş ve İngilizce şarkı filtresi kullanılarak şarkıların İngilizce olduğundan emin olunmuştur. Her şarkıya ait özellikler, Tablo 4.6'da listelenen sütunlarla temsil edilmiştir.

Tablo 4.6 Duygu Analizi için Kullanılan Veri Kümesinin Sütunları


Sütun Adı	Açıklama
track_id	Şarkıya ait benzersiz kimlik
title	Şarkı adı
artist	Şarkıyı seslendiren sanatçı
genre	Şarkının türü
popularity	Spotify üzerindeki popülerite skoru
release_year	Yayın yılı
lyrics	Şarkı sözleri

Veri kümesindeki örneklerin şarkı türlerine göre dağılım Tablo 4.7’de sunulmuştur. Pop, rock, hip-hop, r&b, country ve blues olmak üzere 6 türde toplanan bu örnekler, duygu analizinin türe göre karşılaştırmalı değerlendirmelerini mümkün kılmaktadır.

Tablo 4.7 Duygu Analizi için Kullanılan Veri Kümesinin Türlere Göre Örnek Sayısı


Tür	Örnek Sayısı
pop	1.537
blues	1.528
country	1.393
rock	1.269
hip-hop	1.353
r&b	139

Veri kümesinin yayın yılına göre dağılımı Şekil 4.5’te gösterilmektedir. Grafikten, şarkıların farklı dönemlerden seçildiği ve özellikle son yıllarda daha fazla örnek içerdiği görülmektedir.



Şekil 4.5 Duygu Analizi için Kullanılan Veri Kümesinin Yayın Yılına Göre Dağılımı

Şarkıların Spotify popülerite puanlarına göre dağılımı Şekil 4.6’da gösterilmektedir. Grafikte, çoğu şarkının orta popülerite aralığında yoğunlaştığı görülmektedir. Bu yapı, popülerite ile duygu ilişkilerinin analiz edilmesi için gerekli ortamı oluşturmaktadır.



Şekil 4.6 Duygu Analizi için Kullanılan Veri Kümesinin Popülerite Puanlarına Göre Dağılımı

Bu veri seti, eğitilmiş bir duygu analiz modeliyle etiketlendikten sonra şarkıların duygu sınıfları baz alınarak şarkının popülaritesi ve müzik türü gibi özellikleri arasındaki ilişkileri incelenecektir. Bununla birlikte, müzikteki duygusal ifade ile ticari başarı ve müzik türü arasındaki bağlantıya ait bulgular elde edilebilecektir.

4.1.4 Veri Kümelerine Uygulanan İşlemler

Bu bölümde, hem model eğitimi hem de duygu analizi sürecinde kullanılan veri kümelerine uygulanan ön işleme adımları açıklanacaktır. Yapılan işlemler sayesinde veri daha temiz, tutarlı ve modele uygun hale getirilmiştir.

4.1.4.1 Gereksiz Sütunların Silinmesi

Model eğitimi için kullanılan veri kümesinde yer alan "__index_level_0__" adlı sütunun analiz sürecine herhangi bir katkı sağlamadığı görülmüş ve bu sütunun veri kümesinden çıkarılmasına karar verilmiştir. Bu tür teknik indeks sütunlarının bulunması, veri boyutunu gereksiz yere artırmakta ve analiz sırasında kafa karışıklığına yol açabilmektedir. Dolayısıyla, yalın ve anlaşılır bir veri yapısı oluşturmak amacıyla gereksiz sütunlar veri setinden temizlenmiştir.

4.1.4.2 Eksik Verilerin Temizlenmesi

Veri kümesinde bazı satırlarda eksik veriler bulunmaktaydı. Bu eksikliklerin model eğitimi sırasında hata yaratmaması ve yanlış yönlendirmeye neden olmaması için tüm eksik değer içeren kayıtların veri kümesinden çıkarılmasına karar verilmiştir. Böylece sadece tam ve kullanılabilir bilgileri içeren örneklerle çalışma yapılması sağlanmıştır.

4.1.4.3 HTML ve Özel Karakter Temizliği

Hem model eğitimi için kullanılan şarkı sözlerinde hem de duygu analizi için toplanan metinlerde HTML etiketleri, sistemsal ifadeler ve biçimlendirme amaçlı özel karakterler bulunmaktaydı. Veri temizliği sürecinde, model için anlam ifade etmeyen bu karakterlerin temizlenmesine karar verilmiştir. Bu kapsamda şarkı sözlerinde yer alan yönlendirme içerikleri, yapısal başlıklar, numaralandırmalar ve web kaynaklı eklemeler çıkarılmış; metinler yalnızca anlam taşıyan, duygusal içerik barındıran bölümlerle sadeleştirilmiştir. Böylece modelin daha sağlıklı ve odaklı bir şekilde öğrenme yapması amaçlanmıştır.

4.1.4.4 Boşluk Düzeltmeleri

Yapılan temizlik işlemlerinden sonra metinlerde peş peşe birden fazla boşluk bir araya gelmiştir. Bu sorun düzenli ifadeler ile giderilerek tüm metinlerin düzgün boşluk yapısında ve tek satırda toplanması sağlanmıştır. Böylelikle, modelin eğitimi için kullanılacak olan veriler daha düzenli ve işlenebilir hale getirilmiştir.

4.1.4.5 Tekil Kayıt Oluşturma

Veri setinde farklı sanatçılar tarafından aynı şarkı sözlerinin birden fazla kez geçtiği tespit edilmiştir. Bu tekrarlar, 'seq' sütunu üzerinden kontrol edilerek sadece bir tanesi kalacak şekilde kaldırılmıştır. Buna ek olarak, aynı şarkı adı, aynı sanatçı ve aynı şarkı sözü üçlüsüne sahip olan örnekler de yinelenen kayıt olarak değerlendirilerek yalnızca ilk örnek bırakılacak şekilde veri kümesinden çıkarılmıştır. Böylece veri kümesi içerisinde benzersiz kayıtlar elde edilerek modelin aynı içerikten birden fazla kez etkilenmesi önlenmiştir.

4.1.5 Veri Yapısı ve Saklama Biçimi

Proje için kullanılacak olan veriler, hem model eğitimi hem de duygu analizi aşamalarında işlenebilmesi için düzenlenmiş bir yapıya getirilmiştir. Duygu etiketli eğitim verileri ve toplanan şarkı verileri ayrı ayrı olacak şekilde CSV dosyalarında

depolanmıştır. Bu veri kümelerinin her satırında metin bilgisi ile birlikte o veriye ait varsa duygu etiketi, tür, yıl, popülerite skoru gibi meta bilgiler yer almaktadır. Bu veri yapısı, Python ortamında Pandas ve benzeri kütüphaneler aracılığıyla kolayca işlenebilecek şekilde oluşturulmuştur.

4.1.6 Augmentasyon İşlemi ve Sınırlama

Hazır veri kümesi üzerine uygulanan augmentasyon işleminde Parrot Parapheser [17] modeli kullanılarak şarkı sözlerinin etiket değeri bozulmadan arttırma işlemi yapılmıştır. Bu işlem, veri kümesinin anlam değerini bozabileceğinden dolayı hazır veri kümesindeki sınıf bazlı örnek sayısından daha fazla örnek üretilmemiştir. Kısmi ve tam dengeyi sağlamak amacıyla arttırma işlemi gereken sınıflar olduğu gibi örnek sayıları fazla olan sınıflar da vardır. Bu doğrultuda, bazı sınıflara da rastgele örnek eksiltme işlemi uygulanmıştır.

4.2 Metot

Bu bölümde projede kullanılan metotlar hakkında bilgi verilecektir. Üç farklı model ele alınacak ve her birinin mimari yapısı, özellikleri ve kullanım avantajları açıklanacaktır.

4.2.1 BERT

Google tarafından 2018 yılında geliştirilen BERT modeli, doğal dil işleme alanında önemli bir dönüm noktası olarak görülmektedir. Modelin geliştirilme amacı tek yönlü geleneksel dil modellerinin sınırlamalarını aşmaktır. Metindeki bağlamı sadece kelimenin öncesindeki veya sonrasındaki kelimelere bakarak anlamaya çalışan modellerin aksine, BERT çift yönlü bağlamdan faydalanarak kelime anlamını diğer modellerden daha doğru bir şekilde anlayabilmektedir. Bu özelliği sayesinde BERT modeli, önceden eğitilmiş bir dil modeli olarak farklı doğal dil işleme görevlerine sadece son katmanın eklenmesiyle uyarlanabilmektedir. Bu yöntem ile, soru-cevap sistemlerinden duygu analizine kadar pek çok alanda üstün başarı ve performanslar elde edilebilmektedir [2].

4.2.1.1 Modelin Mimari Yapısı ve Özellikleri

BERT'in mimarisi, yalnızca encoder katmanlarından oluşan çok katmanlı bir transformer yapısından oluşmaktadır. Bu yapı, Vaswani ve arkadaşlarının 2017 yılında tanıttığı "Attention is All You Need" adlı çalışmadan esinlenilerek oluşturulmuştur [18]. Modelin iki yaygın varyasyonu bulunmaktadır:

- **BERT-Base:** 12 encoder katmanı, 768 boyutlu gizli katmanlar, 12 adet multi-head attention mekanizması ve yaklaşık 110 milyon parametre içermektedir.
- **BERT-Large:** 24 encoder katmanı, 1024 boyutlu gizli katmanlar, 16 multi-head attention mekanizması ve yaklaşık 340 milyon parametre içermektedir

BERT'in eğitim aşaması iki temel ön görev üzerine kurulmuştur:

- **Masked Language Modeling (MLM):** Girdi cümlesindeki kelimelerin rastgele %15'i maskelenerek modelin bu kelimeleri bağlamdan tahmin etmesi beklenmektedir. Bu yaklaşımla, çift yönlü bağlamsal bilgi kullanımı sağlanılmaktadır.
- **Next Sentence Prediction (NSP):** Modelin iki cümle arasındaki ilişkiyi anlamasını sağlamak amacıyla, bir cümlenin peşinden gelen cümle ile ilişkili olup olmadığını tahmin etmesi beklenilmektedir.

Bu iki görev ile birlikte BERT, hem cümle düzeyinde hem de kelime düzeyinde bağlamsal anlamlar oluşturabilmektedir.

4.2.1.2 Modelin Kullanım Avantajları

BERT'in en büyük avantajı, klasik doğal dil işleme metotlarının aksine bağlamı çift yönlü olarak değerlendirebilmesidir. Bu özellik, özellikle duygu analizi gibi bağlamın güçlü biçimde anlamı etkilediği görevlerde önemli performans artışları sağlamaktadır. Ayrıca, önceden geniş bir veri kümesiyle eğitilmiş olması nedeniyle, az veriyle bile yapılan ince ayarlarla yüksek doğruluk değerleri elde edilebilmektedir. HuggingFace gibi açık kaynaklı kütüphaneler aracılığıyla kolay erişilebilir olması ve farklı boyutlardaki sürümlerinin olmasıyla hem güçlü donanımlara hem de sınırlı kaynaklara sahip sistemlerde kullanılabilir olması, BERT'i pratikte oldukça esnek bir model haline getirmiştir. Bu projede BERT, temel bir referans modeli olarak değerlendirilmiş ve diğer gelişmiş sürümleri ile karşılaştırmalı olarak kullanılmıştır.

4.2.2 RoBERTa

Facebook AI tarafından 2019 yılında geliştirilen RoBERTa (A Robustly Optimized BERT Pretraining Approach) modeli, BERT modeline dayanan bir doğal dil işleme modelidir. Bu model, BERT'in ön eğitim aşamasının daha dikkatli bir şekilde yeniden değerlendirilmesiyle oluşturulmuştur. Yapılan çalışmayla, BERT'in eğitim

sürecinde bazı tasarım kararlarının yeterince optimize edilmediği ve bu eksikliklerin düzeltilmesiyle birlikte önemli performans artışları elde edilebileceği gösterilmiştir. RoBERTa, BERT ile aynı temel mimariden oluşmaktadır ancak eğitim sürecinde kullanılan veri miktarının artırılması, dinamik maskeleme uygulanması, cümle sıralama görevinden vazgeçilmesi gibi iyileştirmelerle BERT'ten daha güçlü hale getirilmiştir. Özellikle GLUE (The General Language Understanding Evaluation), SQuAD (The Stanford Question Answering Dataset) ve RACE (The Reading Comprehension from Examinations) gibi yaygın olarak kullanılan benchmark veri kümelerinde, RoBERTa ile dönemin en yüksek sonuçlarına ulaşılmıştır [19].

4.2.2.1 Modelin Mimari Yapısı ve Özellikleri

RoBERTa, BERT ile aynı transformer tabanlı encoder mimarisine sahiptir. Yani çok katmanlı, çok başlı self-attention mekanizması kullanılarak çalışır. RoBERTa'nın mimari yapılandırmaları BERT-Base ve BERT-Large ile uyumludur:

- **RoBERTa-Base:** 12 katman, 768 boyutlu gizli katmanlar, 12 attention başlığı ve yaklaşık 125 milyon parametre içermektedir.
- **RoBERTa-Large:** 24 katman, 1024 boyutlu gizli katmanlar, 16 attention başlığı ve yaklaşık 355 milyon parametre içermektedir.

Ancak mimari yapı aynı olsa da, RoBERTa'yı BERT'ten ayıran bazı önemli farklılıklar bulunmaktadır:

- BERT modelinden farklı olarak NSP görevinden vazgeçilmiştir. BERT'in ön eğitiminde kullanılan bu yardımcı görev, RoBERTa'da modelin başarımına anlamlı katkı sağlamadığı gerekçesiyle çıkarılmıştır.
- BERT modeline ek olarak dinamik maskelenmiş dil modelleme uygulanmıştır. BERT'in ön eğitiminde sabit bir şekilde önceden belirlenmiş maskelerle çalışılırken, RoBERTa her eğitim örneğinde maskelenmiş kelimeleri rastgele seçerek modeli daha çeşitli bağlamlarla karşılaştırmıştır.
- BERT modelinden farklı olarak daha büyük ve çeşitli veri kümeleri kullanılmıştır. BERT'in yalnızca Wikipedia ve BookCorpus verileriyle eğitilmesine karşın, RoBERTa ayrıca CommonCrawl News, OpenWebText ve Stories gibi toplamda 160 GB büyüklüğünde geniş bir metin koleksiyonu ile eğitilmiştir.
- Eğitim süresi ve batch boyutu artırılmıştır. RoBERTa, BERT'ten çok daha uzun süre eğitilmiş ve çok daha büyük batch boyutları kullanılarak öğrenme süreci optimize edilmiştir.

4.2.2.2 Modelin Kullanım Avantajları

RoBERTa'nın en belirgin avantajlarından birisi, BERT'in mimarisini korurken eğitim sürecinde yapılan iyileştirmeler ile birlikte daha yüksek performans sağlamasıdır. Özellikle, NSP görevinden vazgeçilmesi ve maskelenmiş kelimelerin dinamik olarak seçilmesiyle birlikte, modelin bağlamsal temsilleri daha verimli öğrenmesi sağlanmıştır. Ayrıca, çok daha büyük ve çeşitli bir veri kümesi üzerinde eğitilmiş olması, farklı türdeki metinlere karşı genelleme yeteneğini oldukça artırmıştır. Bu projede RoBERTa, gelişmiş bir dil temsiline sahip olduğundan dolayı duygu analizi gibi kelimeler arası bağlam duyarlılığı yüksek bir görevde kullanılmak üzere tercih edilmiştir.

4.2.3 DeBERTaV3

Microsoft tarafından 2023 yılında geliştirilen DeBERTaV3 (Disentangled and ELECTRA-Based Representation with Gradient-Aware Pretraining) modeli; BERT, RoBERTa, DeBERTa, ELECTRA modellerinin güçlü yönleri bir araya getirilerek oluşturulan gelişmiş bir doğal dil işleme modelidir. Bu model, DeBERTa mimarisine dayanmaktadır ancak daha verimli bir ön eğitim stratejisi olan Replaced Token Detection görevini benimseyerek ELECTRA yaklaşımını kullanmaktadır. Bu birleşim sayesinde DeBERTaV3, geleneksel MLM görevine kıyasla daha verimli ve daha düşük maliyetli bir ön eğitim süreci sunmaktadır. Model, aynı mimariye sahip rakiplerinden büyük ölçüde daha yüksek performans göstermektedir. GLUE gibi doğal dil anlama benchmark'larında elde edilen başarılarla birlikte, DeBERTaV3 güncel durumu yansıtan en güçlü modellerden biri haline gelmiştir [20].

4.2.3.1 Modelin Mimari Yapısı ve Özellikleri

DeBERTaV3 modeli, üç temel mimari yeniliğin bir araya getirilmesiyle oluşturulmuştur. Bu yenilikler ile birlikte hem bağlamsal temsil gücü artırılmış hem de eğitim süreci daha verimli hale getirilmiştir.

- **Disentangled Attention (DA):** Klasik transformer modellerinde kelimenin içeriği ve konumu tek bir vektörde kodlanırken, DeBERTa mimarisinde bu iki bilgi ayrı ayrı temsil edilmektedir. Böylece, içerik ve pozisyon bilgileri birbirinden bağımsız olarak işlenebilmiş, bu da bağlamsal ilişkilerin daha hassas biçimde öğrenilmesini sağlamıştır.
- **Replaced Token Detection (RTD):** BERT gibi modellerde kullanılan MLM yerine, ELECTRA'dan alınan RTD yöntemi benimsenmiştir. Bu yöntemde, bir

generator tarafından rastgele değiştirilmiş kelimeleri ayırt etme görevi modelin discriminator bileşeni tarafından yerine getirilmektedir. RTD, klasik MLM'ye kıyasla daha gerçekçi bir öğrenme yapısı sunarak özellikle örnek verimliliğini artırmakta ve daha az veriyle daha iyi performans elde edilmesini sağlamaktadır.

- **Gradient-Disentangled Embedding Sharing (GDES):** RTD görevinde kullanılan generator ve discriminator modellerinin aynı kelime temsillerini paylaşması performansı etkileyebilmektedir. Bu paylaşım klasik yöntemlerde çekişme olarak adlandırılan bir sorun yaratmaktadır. GDES yöntemi sayesinde, discriminator bileşeninden gelen gradyanların generator temsillerini etkilemesi engellenebilmektedir. Böylece, bilgi paylaşımından ödün verilmeden kararlı ve daha etkili bir öğrenme süreci sağlanmıştır.

Bunlara ek olarak, DeBERTaV3 modeli farklı boyut seçenekleriyle önceden eğitilmiş bir şekilde sunulmakta ve bu sayede hem yüksek işlem gücü gerektiren sistemlerde hem de kısıtlı kaynaklarda rahatlıkla kullanılabilmektedir.

4.2.3.2 Modelin Kullanım Avantajları

DeBERTaV3 modeli, önceki modellere kıyasla önemli avantajlar sunmaktadır. RTD görevleri sayesinde örnek verimliliği artırılmış, böylece daha az veri ve işlemle daha yüksek doğrulukta sonuçlar elde edilmiştir. Ayrıca, GDES yöntemiyle modelin temsil öğrenme süreci iyileştirilmiş, bilgi bütünlüğü korunarak daha kararlı ve hızlı bir öğrenme sağlanmıştır. Bu mimari ve eğitimsel iyileştirmelerin bir sonucu olarak, GLUE, SQuAD ve RACE gibi yaygın benchmark testlerinde DeBERTaV3 ile yüksek doğruluk değerleri elde edilmiştir. Bu proje kapsamında DeBERTaV3, modelin gelişmiş bağlamsal anlama kabiliyeti, örnek verimliliği ve kanıtlanmış deneysel başarısı nedeniyle tercih edilmiştir.

4.2.4 Modellerin Karşılaştırılması

Bu çalışmada kullanılan üç temel model olan BERT, RoBERTa ve DeBERTaV3'ün öne çıkan teknik özellikleri ve farklılıkları Tablo 4.8'de özetlenmiştir. Tabloda görüldüğü üzere, BERT modeli doğal dil işleme alanında temel bir yapı taşı olarak değerlendirilmiş; RoBERTa modeli, BERT'in eğitim sürecine yönelik yapılan iyileştirmeler ile daha yüksek doğruluk oranları sağlamıştır. DeBERTaV3 ise, modern eğitim stratejileri ve yenilikçi mimarisi sayesinde hem bağlamsal temsil kabiliyeti hem de işlem verimliliği açısından diğer modellere kıyasla üstünlük göstermektedir. Bu projede her model, kendi yapısal avantajları göz önünde bulundurularak, görev gereksinimlerine ve sistem kaynaklarına uygun şekilde tercih edilmiştir.

Tablo 4.8 Kullanılan Modellerin Karşılaştırılma Tablosu

Özellik	BERT	RoBERTa	DeBERTaV3
Geliştirici	Google	Facebook AI	Microsoft Azure AI
Yayın Yılı	2018	2019	2023
Eğitim Görevi	MLM + NSP	MLM	DA + RTD + GDES
Katman Sayısı (Base)	12	12	12
Parametre Sayısı (Base)	~110 Milyon	~125 Milyon	~86 Milyon
Pozisyon Temsili	Mutlak	Mutlak	Ayrık + Bağlı
Öne Çıkan Özellik	Çift Yönlü Bağlam	Dinamik Maskeleme	RTD + GDES + DA ile Yüksek Verimlilik
Verimlilik	Orta	Yüksek	En yüksek

5

DENEYSEL SONUÇLAR

Bu bölümde, farklı veri setleri ile eğitilen modellerin parametreleri ve performansları hakkında bilgi verilecektir. Bu modeller arasından karşılaştırma yapılarak en iyi model belirlenecektir. En iyi model ile power analysis ve ground truth analizi yapılacaktır. Son olarak, en iyi model kullanılarak toplanan veri seti üzerinde duygu analizi yapılacaktır.

5.1 Performans Analizi

Bu bölümde, şarkı sözlerindeki duyguları sınıflandırmak üzere eğitilen BERT, RoBERTa ve DeBERTaV3 modellerinin performans analizi yapılacaktır. Tüm modeller 3 adet veri setiyle eğitilmiş olup veri setlerinin %80'i eğitim için, %10'u eğitim sırasında doğrulama için ve kalan %10'u ise test için kullanılmıştır. Bu dağılım sınıflardaki örnek sayıları tutarlı olacak şekilde gerçekleştirilmiştir. Ayrıca Dataset 1 ve Dataset 2 ile eğitim yapılırken sınıf ağırlıkları kullanılarak daha duyarlı bir çözüm elde edilmeye çalışılmıştır. Eğitim sonunda ortalama ağırlıklı F1 skoru en yüksek olan model seçilmiş ve aşırı öğrenmeden kaçınılması için bu skorun peş peşe iki kez düşüş gerçekleştirmesiyle eğitim sonlandırılmıştır. Modellere ait diğer parametreler ise her model için ayrı ayrı bahsedilecektir.

5.1.1 BERT Modeli

BERT modeli, şarkı sözlerindeki duyguları sınıflandırmak amacıyla eğitilmiştir. Modelin eğitimi sırasında seçilen hiperparametreler hem literatürdeki yaygın uygulamalar hem de çeşitli hiperparametrelerin farklı değerleriyle denenmesi ile elde edilen gözlemler dikkate alınarak belirlenmiş, modelin en iyi bir şekilde duygu sınıflarını doğru ayırt edebilmesi amaçlanmıştır. Model eğitimi için belirlenen parametreler Tablo 5.1'deki gibidir.

Tablo 5.1 BERT Modeli Parametreleri

Parametre	Değer
Batch Size	64
Learning Rate	2e-5
Epoch	10
Weight Decay	0.05
Warmup Ratio	0.1
Learning Rate Scheduler	cosine_with_restarts
Label Smoothing Factor	0.1

BERT gibi büyük modellerde ani ağırlık güncellemelerinden kaçınmak için genellikle küçük öğrenme oranları kullanıldığından dolayı learning rate olarak 2e-5 değeri seçilmiştir. Model eğitiminin başında öğrenme oranının düzgün bir şekilde artması warmup ratio parametresiyle sağlanmıştır. Öğrenme oranı zamanlayıcısıyla her epoch'da farklı bir öğrenme oranı kullanılarak modelin daha iyi minimumlara ulaşabilmesi sağlanılmıştır. Label smoothing parametresi ile modelin kendine aşırı güvenmesi engellenerek daha tutarlı tahminler yapması sağlanmış, genelleme kapasitesi artırılmıştır. Aşırı öğrenmenin önüne geçilmesi ise weight decay parametresiyle sağlanılmıştır. Son olarak, öğrenme sürecinin dengeli ilerlemesi ve bellek kullanımında verimlilik sağlanması amacıyla da batch boyutu 64 olarak belirlenmiştir.

5.1.1.1 Dataset 1 ile Eğitilmiş BERT Modeline Ait Sınıflandırma Raporu


Dataset 1 ile eğitilmiş BERT modeli için sınıflandırma raporu Şekil 5.1'deki gibidir.

	precision	recall	f1-score	support
fear	0.76	0.82	0.79	831
sadness	0.86	0.78	0.82	740
surprise	0.65	0.67	0.66	130
anger	0.70	0.72	0.71	334
joy	0.81	0.76	0.78	175
disgust	0.80	0.80	0.80	138
accuracy			0.78	2348
macro avg	0.76	0.76	0.76	2348
weighted avg	0.78	0.78	0.78	2348

Şekil 5.1 Dataset 1 ile Eğitilmiş BERT Modeline Ait Sınıflandırma Raporu

5.1.1.2 Dataset 1 ile Eğitilmiş BERT Modeline Ait Karmaşıklık Matrisi

Dataset 1 ile eğitilmiş BERT Modeli için karmaşıklık matrisi Şekil 5.2'deki gibidir.



Şekil 5.2 Dataset 1 ile Eğitilmiş BERT Modeline Ait Karmaşıklık Matrisi

5.1.1.3 Dataset 2 ile Eğitilmiş BERT Modeline Ait Sınıflandırma Raporu


Dataset 2 ile eğitilmiş BERT modeli için sınıflandırma raporu Şekil 5.3'teki gibidir.

	precision	recall	f1-score	support
fear	0.71	0.76	0.73	400
sadness	0.82	0.80	0.81	400
anger	0.82	0.76	0.79	404
disgust	0.85	0.89	0.87	192
joy	0.89	0.92	0.91	364
surprise	0.87	0.87	0.87	299
accuracy			0.82	2059
macro avg	0.83	0.83	0.83	2059
weighted avg	0.82	0.82	0.82	2059

Şekil 5.3 Dataset 2 ile Eğitilmiş BERT Modeline Ait Sınıflandırma Raporu

5.1.1.4 Dataset 2 ile Eğitilmiş BERT Modeline Ait Karmaşıklık Matrisi

Dataset 2 ile eğitilmiş BERT Modeli için karmaşıklık matrisi Şekil 5.4'teki gibidir.



Şekil 5.4 Dataset 2 ile Eğitilmiş BERT Modeline Ait Karmaşıklık Matrisi

5.1.1.5 Dataset 3 ile Eğitilmiş BERT Modeline Ait Sınıflandırma Raporu


Dataset 3 ile eğitilmiş BERT modeli için sınıflandırma raporu Şekil 5.5'teki gibidir.

	precision	recall	f1-score	support
fear	0.72	0.55	0.62	200
sadness	0.75	0.80	0.77	200
surprise	0.87	0.78	0.82	200
anger	0.75	0.70	0.73	200
joy	0.80	0.93	0.86	200
disgust	0.80	0.94	0.86	200
accuracy			0.78	1200
macro avg	0.78	0.78	0.78	1200
weighted avg	0.78	0.78	0.78	1200

Şekil 5.5 Dataset 3 ile Eğitilmiş BERT Modeline Ait Sınıflandırma Raporu

5.1.1.6 Dataset 3 ile eğitilmiş BERT Modeline Ait Karmaşıklık Matrisi

Dataset 3 ile eğitilmiş BERT Modeli için karmaşıklık matrisi Şekil 5.6'daki gibidir.



Şekil 5.6 Dataset 3 ile Eğitilmiş BERT Modeline Ait Karmaşıklık Matrisi

5.1.2 RoBERTa Modeli

RoBERTa modeli, BERT mimarisine benzer yapıya sahip olmasına rağmen daha yoğun ve kapsamlı bir eğitim sürecinden geçtiği için bağlamı yakalamada BERT modeline göre daha başarılı olabilmektedir. Modelin eğitimi sırasında seçilen hiperparametreler hem literatürdeki yaygın uygulamalar hem de çeşitli hiperparametrelerin farklı değerleriyle denenmesi ile elde edilen gözlemler dikkate alınarak belirlenmiş, modelin en iyi bir şekilde duygu sınıflarını doğru ayırt edebilmesi amaçlanmıştır. Model eğitimi için belirlenen parametreler Tablo 5.2'deki gibidir.

Tablo 5.2 RoBERTa Modeli Parametreleri

Parametre	Değer
Batch Size	64
Learning Rate	3e-5
Epoch	10
Weight Decay	0.01
Warmup Ratio	0.05
Learning Rate Scheduler	cosine
Label Smoothing Factor	0.075

Ani ağırlık güncellemelerinden kaçınmak için genellikle küçük öğrenme oranları kullanıldığından dolayı learning rate olarak 3e-5 değeri seçilmiştir. Model eğitiminin başında öğrenme oranının düzgün bir şekilde artması warmup ratio parametresiyle sağlanmıştır. Öğrenme oranı zamanlayıcısı olarak cosine değeri seçilmiş ve modelin eğitim ilerledikçe öğrenme oranını yavaşça düşürerek stabil bir şekilde yakınsaması sağlanmıştır. Label smoothing parametresi ile modelin kendine aşırı güvenmesi engellenerek daha tutarlı tahminler yapması sağlanmış, genelleme kapasitesi arttırılmıştır. Epoch sayısı 10 olarak belirlenerek modelin yeterli performansa ulaşabilmesi sağlanmıştır. Aşırı öğrenmenin önüne geçilmesi ise weight decay değerinin 0.01 gibi görece küçük bir değerle belirlenmesiyle sağlanılmıştır. Son olarak, öğrenme sürecinin dengeli ilerlemesi ve bellek kullanımında verimlilik sağlanması amacıyla da batch boyutu 64 olarak belirlenmiştir.

5.1.2.1 Dataset 1 ile Eğitilmiş RoBERTa Modeline Ait Sınıflandırma Raporu


Dataset 1 ile eğitilmiş RoBERTa modeli için sınıflandırma raporu Şekil 5.7'deki gibidir.

	precision	recall	f1-score	support
fear	0.83	0.83	0.83	831
sadness	0.86	0.86	0.86	740
surprise	0.69	0.68	0.68	130
anger	0.76	0.78	0.77	334
joy	0.85	0.82	0.83	175
disgust	0.84	0.83	0.84	138
accuracy			0.82	2348
macro avg	0.80	0.80	0.80	2348
weighted avg	0.82	0.82	0.82	2348

Şekil 5.7 Dataset 1 ile Eğitilmiş RoBERTa Modeline Ait Sınıflandırma Raporu

5.1.2.2 Dataset 1 ile Eğitilmiş RoBERTa Modeline Ait Karmaşıklık Matrisi

Dataset 1 ile eğitilmiş RoBERTa modeli için karmaşıklık matrisi Şekil 5.8'deki gibidir.



Şekil 5.8 Dataset 1 ile Eğitilmiş RoBERTa Modeline Ait Karmaşıklık Matrisi

5.1.2.3 Dataset 2 ile Eğitilmiş RoBERTa Modeline Ait Sınıflandırma Raporu


Dataset 2 ile eğitilmiş RoBERTa modeli için sınıflandırma raporu Şekil 5.9'daki gibidir.

	precision	recall	f1-score	support
fear	0.77	0.78	0.77	400
sadness	0.86	0.79	0.82	400
anger	0.85	0.81	0.83	404
disgust	0.83	0.94	0.88	192
joy	0.89	0.92	0.91	364
surprise	0.86	0.87	0.86	299
accuracy			0.84	2059
macro avg	0.84	0.85	0.85	2059
weighted avg	0.84	0.84	0.84	2059

Şekil 5.9 Dataset 2 ile Eğitilmiş RoBERTa Modeline Ait Sınıflandırma Raporu

5.1.2.4 Dataset 2 ile Eğitilmiş RoBERTa Modeline Ait Karmaşıklık Matrisi

Dataset 2 ile eğitilmiş RoBERTa Modeli için karmaşıklık matrisi Şekil 5.10'daki gibidir.



Şekil 5.10 Dataset 2 ile Eğitilmiş RoBERTa Modeline Ait Karmaşıklık Matrisi

5.1.2.5 Dataset 3 ile Eğitilmiş RoBERTa Modeline Ait Sınıflandırma Raporu


Dataset 3 ile eğitilmiş RoBERTa modeli için sınıflandırma raporu Şekil 5.11'deki gibidir.

	precision	recall	f1-score	support
fear	0.72	0.66	0.69	200
sadness	0.81	0.81	0.81	200
surprise	0.80	0.89	0.84	200
anger	0.74	0.80	0.77	200
joy	0.96	0.84	0.90	200
disgust	0.88	0.92	0.90	200
accuracy			0.82	1200
macro avg	0.82	0.82	0.82	1200
weighted avg	0.82	0.82	0.82	1200

Şekil 5.11 Dataset 3 ile Eğitilmiş RoBERTa Modeline Ait Sınıflandırma Raporu

5.1.2.6 Dataset 3 ile Eğitilmiş RoBERTa Modeline Ait Karmaşıklık Matrisi

Dataset 3 ile eğitilmiş RoBERTa Modeli için karmaşıklık matrisi Şekil 5.12'deki gibidir.



Şekil 5.12 Dataset 3 ile Eğitilmiş RoBERTa Modeline Ait Karmaşıklık Matrisi

5.1.3 DeBERTaV3 Modeli

DeBERTaV3 modeli, bağlamsal ilişkileri yakalamada diğer iki modele göre daha derin ve geniş mimarisi sayesinde daha gelişmiş bir kapasiteye sahiptir. Bu yapısal farklılık nedeniyle, modelin eğitim sürecinde bazı hiperparametreler özel olarak ayarlanmış, hem literatürdeki yaygın uygulamalar hem de çeşitli hiperparametrelerin farklı değerleriyle denenmesi ile elde edilen gözlemler dikkate alınarak belirlenmiş, modelin en iyi bir şekilde duygu sınıflarını doğru ayırt edebilmesi amaçlanmıştır. Model eğitimi için belirlenen parametreler Tablo 5.3'teki gibidir.

Tablo 5.3 DeBERTaV3 Modeli Parametreleri

Parametre	Değer
Batch Size	16
Gradient Accumulation Steps	4
Learning Rate	1e-5
Epoch	10
Weight Decay	0.05
Warmup Ratio	0.1
Learning Rate Scheduler	cosine_with_restarts
Label Smoothing Factor	0.1

DeBERTaV3 modeli diğer iki modelden daha küçük yavaş bir öğrenme sürecine sahip olduğu için learning rate olarak 1e-5 değeri seçilerek ani ağırlık değişimlerinin önüne geçilmiştir. Model eğitiminin başında öğrenme oranının düzgün bir şekilde artması warmup ratio parametresiyle sağlanmıştır. Öğrenme oranı zamanlayıcısıyla her epoch'da farklı bir öğrenme oranı kullanılarak modelin daha iyi minimumlara ulaşabilmesi sağlanılmıştır. Label smoothing parametresi ile modelin kendine aşırı güvenmesi engellenerek daha tutarlı tahminler yapması sağlanmış, genelleme kapasitesi artırılmıştır. Epoch sayısı 10 olarak belirlenerek modelin yeterli performansa ulaşabilmesi sağlanılmıştır. Aşırı öğrenmenin önüne geçilmesi ise weight decay değerinin 0.05 olarak belirlenmesiyle sağlanılmıştır. Son olarak, diğer modellere göre daha büyük olmasından ve sınırlı bellek boyutundan dolayı batch size değeri 16 olarak belirlenmiştir. Bu küçük batch boyutu eğitim başarısını olumsuz etkilememesi için gradient accumulation steps değeri olarak 4 belirlenmiş, böylece efektif batch boyutu 64'e çıkarılarak performans kaybının önüne geçilmesi amaçlanmıştır.

5.1.3.1 Dataset 1 ile Eğitilmiş DeBERTaV3 Modeline Ait Sınıflandırma Raporu


Dataset 1 ile eğitilmiş DeBERTaV3 modeli için sınıflandırma raporu Şekil 5.13'teki gibidir.

	precision	recall	f1-score	support
fear	0.84	0.74	0.79	831
sadness	0.81	0.81	0.81	740
surprise	0.59	0.75	0.66	130
anger	0.70	0.72	0.71	334
joy	0.77	0.83	0.80	175
disgust	0.66	0.83	0.73	138
accuracy			0.77	2348
macro avg	0.73	0.78	0.75	2348
weighted avg	0.78	0.77	0.77	2348

Şekil 5.13 Dataset 1 ile Eğitilmiş DeBERTaV3 Modeline Ait Sınıflandırma Raporu

5.1.3.2 Dataset 1 ile Eğitilmiş DeBERTaV3 Modeline Ait Karmaşıklık Matrisi

Dataset 1 ile eğitilmiş DeBERTaV3 Modeli için karmaşıklık matrisi Şekil 5.14'teki gibidir.



Şekil 5.14 Dataset 1 ile Eğitilmiş DeBERTaV3 Modeline Ait Karmaşıklık Matrisi

5.1.3.3 Dataset 2 ile Eğitilmiş DeBERTaV3 Modeline Ait Sınıflandırma Raporu


Dataset 2 ile eğitilmiş DeBERTaV3 modeli için sınıflandırma raporu Şekil 5.15'teki gibidir.

	precision	recall	f1-score	support
fear	0.73	0.65	0.69	400
sadness	0.74	0.80	0.77	400
anger	0.78	0.71	0.74	404
disgust	0.69	0.93	0.79	192
joy	0.85	0.87	0.86	364
surprise	0.84	0.76	0.80	299
accuracy			0.77	2059
macro avg	0.77	0.79	0.77	2059
weighted avg	0.77	0.77	0.77	2059

Şekil 5.15 Dataset 2 ile Eğitilmiş DeBERTaV3 Modeline Ait Sınıflandırma Raporu

5.1.3.4 Dataset 2 ile Eğitilmiş DeBERTaV3 Modeline Ait Karmaşıklık Matrisi

Dataset 2 ile eğitilmiş DeBERTaV3 Modeli için karmaşıklık matrisi Şekil 5.16'daki gibidir.



Şekil 5.16 Dataset 2 ile Eğitilmiş DeBERTaV3 Modeline Ait Karmaşıklık Matrisi

5.1.3.5 Dataset 3 ile Eğitilmiş DeBERTaV3 Modeline Ait Sınıflandırma Raporu


Dataset 3 ile eğitilmiş DeBERTaV3 modeli için sınıflandırma raporu Şekil 5.17'deki gibidir.

	precision	recall	f1-score	support
fear	0.57	0.61	0.59	200
sadness	0.70	0.72	0.71	200
surprise	0.74	0.74	0.74	200
anger	0.69	0.54	0.61	200
joy	0.81	0.81	0.81	200
disgust	0.79	0.87	0.83	200
accuracy			0.72	1200
macro avg	0.72	0.72	0.71	1200
weighted avg	0.72	0.72	0.71	1200

Şekil 5.17 Dataset 3 ile Eğitilmiş DeBERTaV3 Modeline Ait Sınıflandırma Raporu

5.1.3.6 Dataset 3 ile Eğitilmiş DeBERTaV3 Modeline Ait Karmaşıklık Matrisi

Dataset 3 ile eğitilmiş DeBERTaV3 Modeli için karmaşıklık matrisi Şekil 5.18'deki gibidir.



Şekil 5.18 Dataset 3 ile Eğitilmiş DeBERTaV3 Modeline Ait Karmaşıklık Matrisi

5.2 Karşılaştırmalı Analiz

Bu bölümde, üç farklı doğal dil işleme modeli olan BERT, RoBERTa ve DeBERTaV3'ün, 3 farklı veri kümesi üzerindeki duygu sınıflandırma performansları incelenecektir. Bu inceleme sonucunda en iyi sonuç veren model seçilerek diğer başlıklar altında kullanılacaktır.

5.2.1 Model Performans Metriklerinin Özeti

Tablo 5.4'te, her modelin her bir veri kümesindeki genel doğruluk, makro duyarlılık, makro kesinlik, makro ortalama F1 skoru ve ağırlıklı ortalama F1 skoru değerleri özetlenmiştir.

Tablo 5.4 Modellere Göre Özet Performans Karşılaştırması

Model	Veri Kümesi	Kesinlik	Duyarlılık	Doğruluk	Makro F1	Ağırlıklı F1
BERT	Dataset 1	0.76	0.76	0.78	0.76	0.78
BERT	Dataset 2	0.83	0.83	0.82	0.83	0.82
BERT	Dataset 3	0.78	0.78	0.78	0.78	0.78
RoBERTa	Dataset 1	0.80	0.80	0.82	0.80	0.82
RoBERTa	Dataset 2	0.84	0.85	0.84	0.85	0.84
RoBERTa	Dataset 3	0.82	0.82	0.82	0.82	0.82
DeBERTaV3	Dataset 1	0.73	0.78	0.77	0.75	0.77
DeBERTaV3	Dataset 2	0.77	0.79	0.77	0.77	0.77
DeBERTaV3	Dataset 3	0.72	0.72	0.72	0.71	0.71

5.2.2 Modeller Arası Genel Performans Karşılaştırılması

RoBERTa modeli, tartışmasız liderdir. Üç veri kümesinde de en yüksek doğruluk ve F1 skorlarına ulaşarak tutarlı bir üstünlük sergilemiştir. Özellikle Dataset 2'de %84 doğruluk ve %85 F1 skoru ile en yüksek başarısını elde etmiştir. Bu, RoBERTa'nın farklı veri dağılımları ve boyutlarıyla en iyi şekilde başa çıkabilen ve genelleme yeteneği en yüksek model olduğunu göstermektedir.

BERT, sağlam ve tutarlı bir performans izleyerek ikinci sırada yer almaktadır. RoBERTa'ya kıyasla daha düşük olsa da, performansında büyük düşüşler yaşanmamıştır. Dataset 2'de veri kümesi dengelemesinin faydalarını göstererek en yüksek performansına ulaşmıştır.

DeBERTaV3, diğer iki modele kıyasla en düşük performansı sergilemiştir. Özellikle Dataset 3'teki %72 doğruluk ve %71 F1 skoru ile belirgin bir düşüş gözlemlenmiştir. Bu, DeBERTaV3'ün bu tür duygu sınıflandırma görevleri için veya kullanılan veri

artırma yöntemleri ile veri seti boyutları altında en uygun model olmayabileceğini düşündürmektedir.

5.2.3 Veri Dengeleme Stratejilerinin Model Performansı Üzerindeki Etkileri

Bu bölümde, veri kümelerinin özelliklerine göre modellerin performansı değerlendirilecektir.

5.2.3.1 Dataset 1

Bu veri kümesindeki ‘fear’ ve ‘sadness’ sınıflarının baskın olması ve ‘disgust’ azınlık sınıfının kısmen artırılması, modellerin performansında belirli eğilimleri ortaya koymuştur.

RoBERTa’nın burada bile %82’lik bir doğruluk elde etmesi, modelin dengesiz veri dağılımlarına karşı sağlamlığını veya baskın sınıflardan etkili bir şekilde öğrenebildiğini göstermektedir.

DeBERTaV3’ün Dataset 1’de ‘surprise’ ve ‘disgust’ gibi azınlık sınıflarda yüksek duyarlılık değerleri göstermesi ancak kesinliklerinin düşük olması, modelin bu sınıfları yakalamaya çalıştığını ancak çok sayıda yanlış pozitif ürettiğini, yani fazla genellediğini veya tam olarak anlayamadığını düşündürmektedir.

5.2.3.2 Dataset 2

Sınıf aralıklarının azaltılarak dengelenmesiyle birlikte ‘disgust’, ‘surprise’, ‘joy’ gibi sınıflar için yapılan augmentasyonun faydaları açıkça görülmektedir.

Tüm modellerde genel bir performans artışı gözlemlenmiştir, bu da veri dengelemesinin ve artırmanın önemini bir kez daha doğrulamaktadır.

Özellikle, RoBERTa, Dataset 2’de zirve performansına ulaşarak dengelenmiş ve orta boyutlu veri kümelerinden en iyi şekilde faydalandığını kanıtlamıştır. Bu, modellerin azınlık sınıflarını daha iyi öğrenmesine olanak sağlamıştır.

5.2.3.3 Dataset 3

Bu veri kümesi, fazla sayıda örneğe sahip olan sınıflarda rastgele seçim yapılarak, az sayıda örneğe sahip olan sınıflarda ise augmentasyon yapılarak her sınıfta toplam 2000 örnek olacak şekilde oluşturulmuştur ve tamamen dengeli bir yapıya sahiptir.

RoBERTa ve BERT'in performansı, Dataset 1'e benzer ve Dataset 2'den biraz düşük seyreitse de, genel başarılarını korumuşlardır. Bu, RoBERTa'nın küçük ve dengeli sentetik veri setlerinde dahi yüksek performansını sürdürebildiğini göstermektedir.

DeBERTaV3'ün performansı bu veri kümesinde belirgin bir düşüş yaşamıştır. Bu durum, DeBERTaV3'ün sentetik veriyle tamamen dengelenmiş ancak nispeten küçük veri kümelerinde genelleme yeteneğinin sınırlı olduğunu veya sentetik verilerin kalitesine daha duyarlı olduğunu düşündürmektedir. Model, artırılmış veriyi diğer modeller kadar iyi kullanamamış olabilir.

5.2.4 Duygu Sınıflarına Özgü Gözlemler

'Joy' ve 'Sadness': Bu duygular, genellikle tüm modellerde yüksek ve tutarlı F1 skorları elde etmiştir. Bu durum, bu duyguların metinlerde daha belirgin veya tutarlı kalıplara sahip olduğunu ya da eğitim verilerinde doğal olarak daha iyi temsil edildiğini gösterebilir. Özellikle RoBERTa, 'joy' sınıfında sürekli olarak yüksek performans sergilemiştir.

'Surprise' ve 'Disgust': Bu duygular, başlangıçta az örneğe sahip olmaları nedeniyle modeller için daha zorluydu. Ancak veri artırma yöntemleri sayesinde bu sınıflardaki modellerin performansları önemli ölçüde iyileşmiştir. RoBERTa'nın bu kategorilerdeki yüksek F1 skorları, artırma yöntemlerinin bu modeller için özellikle etkili olduğunu vurgulamaktadır.

'Fear' ve 'Anger': Bu sınıflardaki performans, veri kümesinden veri kümesine ve modelden modele değişmiştir. Dataset 3'teki 'fear' performans düşüşü, küçük ve dengelenmiş veri kümelerinde bazı modellerin bu duyguyu tahmin etmekte zorlandığını göstermektedir.

5.2.5 Genel Sonuçlar

Bu analizler doğrultusunda aşağıdaki önemli sonuçlara ulaşılmıştır.

1. RoBERTa, duygu sınıflandırma görevleri için en üstün modeldir. Farklı veri seti boyutları ve dengeleme stratejileri altında en tutarlı ve yüksek performansı sergilemiştir. Modelin, hem dengesiz hem de dengeli veri dağılımlarına başarılı bir şekilde adapte olduğu görülmüştür. Model, Dataset 2 ile birlikte en iyi performansına ulaşmıştır.
2. Veri dengeleme ve artırma stratejileri, model performansını doğrudan etkilemektedir. Özellikle azınlık sınıflarının artırılması, modellerin bu sınıfları

daha iyi öğrenmesine ve genel performansın artmasına yardımcı olmuştur. Dataset 2'deki genel iyileşme bunun en güzel örneğidir.

3. DeBERTaV3, veri kalitesine ve miktarına daha duyarlı görünmektedir. Tamamen dengelenmiş ve sentetik verilerle zenginleştirilmiş küçük veri kümesinde yani Dataset 3'te yaşadığı belirgin performans düşüşü, bu modelin daha doğal, çeşitli ve yeterli miktarda veriyle daha iyi sonuçlar verebileceğini düşündürmektedir. Sentetik veri kalitesi veya miktarı DeBERTaV3'ün genelleme yeteneğini kısıtlamış olabilir.

Bu sonuçlarla birlikte diğer aşamalardaki analizlere en iyi performansını Dataset 2 ile sergileyen RoBERTa modeliyle devam edilecektir.

5.3 Power Analysis ve Ground Truth

Bu bölümde, en iyi model olarak seçilen Dataset 2 ile eğitilmiş RoBERTa modeli Power Analysis ve Ground Truth kapsamında incelenecektir.

5.3.1 Power Analysis

Bu kısımda, power analizi için gerekli örneklem sayısını tahmin etmek için NormalIndPower kütüphanesi kullanılmıştır. Altı sınıflı bir veri seti için, etki büyüklüğü (*effect size*) = 0.8, anlamlılık düzeyi (*alpha*) = 0.05 ve testin gücü (*power*) = 0.8 olarak belirlenmiştir. Bu parameterler sonucunda, toplamda 150 örneğe ihtiyaç duyulduğu hesaplanmıştır.

Bu bağlamda, veri setimizden rastgele olacak şekilde 114 örnek seçilmiş ve ekip üyeleri bireysel olarak bu örnekleri etiketlemiştir. Bireysel etiketlemenin sonucunda, Cohen's Kappa = 0.64 değerine ulaşılmıştır. Farklı etiketler incelenerek ortak bir sonuca varılmış ve bu sonuç Ground Truth kısmında kullanılmıştır.

5.3.2 Ground Truth

Bu kısımda, power analizinde ortak belirlenmiş veri seti ve Dataset 2 ile eğitilmiş RoBERTa veri seti kullanılarak analiz yapılacak olan veri setinin model üzerindeki doğruluğunun belirlenmesi amaçlanmıştır. Ortak belirlenen etiketlerin sınıf dağılımı Şekil 5.19'daki gibidir.

	count
label_name	
fear	35
anger	29
sadness	21
disgust	13
surprise	10
joy	6

Şekil 5.19 Etiketleri Ortak Belirlenmiş Veri Kümesinin Sınıf Dağılımı

5.3.2.1 Ground Truth Kapsamında Elde Edilen Sınıflandırma Raporu


Ortak belirlenmiş veri seti ile test edilen en iyi model için sınıflandırma raporu Şekil 5.20'deki gibidir.

	precision	recall	f1-score	support
fear	0.74	0.74	0.74	35
sadness	0.88	0.67	0.76	21
surprise	0.85	0.79	0.82	29
anger	0.53	0.77	0.62	13
joy	1.00	0.50	0.67	6
disgust	0.50	0.70	0.58	10
accuracy			0.73	114
macro avg	0.75	0.70	0.70	114
weighted avg	0.76	0.73	0.73	114

Şekil 5.20 Ground Truth Kapsamında Elde Edilen Sınıflandırma Raporu

5.3.2.2 Ground Truth Kapsamında Elde Edilen Karmaşıklık Matrisi

Ortak belirlenmiş veri seti ile test edilen en iyi model için karmaşıklık matrisi Şekil 5.21'deki gibidir.



Şekil 5.21 Ground Truth Kapsamında Elde Edilen Karmaşıklık Matrisi


Bu analizde, ortak belirlenmiş veri seti üzerinde seçilen en iyi modelin performansı %73 F1 skoru ile birlikte yeterli görülmüştür. Örneklemdaki ‘joy’ etiket sayısının az olması nedeniyle %50 duyarlılık skoru göz ardı edilmiştir.

5.4 Şarkıların Meta Bilgileriyle Duygu Analizi İlişkileri

Bu bölümde, en iyi seçilen model ile birlikte Spotify ve Genius API’leri kullanılarak toplanan verilerin üzerinde duygu analizi etiketlemesi yapılmıştır. Yapılan bu etiketleme sonucunda çeşitli ilişkilerin analizi alt başlıklarla birlikte açıklanacaktır.

5.4.1 Duygu Analizi için Kullanılan Veri Setinin Duygu Dağılımı


Duygu analizi için kullanılan veri setinin duygu dağılımı Şekil 5.22’deki gibidir.



Şekil 5.22 Duygu Analizi için Kullanılan Veri Setinin Duygu Dağılımı Grafiği

5.4.2 Duygu Analizi için Kullanılan Veri Setinin Duygulara Göre Ortalama Popülerlik Skorları


Duygu analizi için kullanılan veri setinin duygulara göre ortalama popülerlik skorları Şekil 5.23'teki gibidir.



Şekil 5.23 Duygu Analizi için Kullanılan Veri Setinin Duygulara Göre Ortalama Popülerlik Skorları Grafiği

5.4.3 Duygu Analizi için Kullanılan Veri Setinin Duygulara Göre Popülerlik Dağılımı


Duygu analizi için kullanılan veri setinin duygulara göre popülerlik dağılımı Şekil 5.24'deki gibidir.



Şekil 5.24 Duygu Analizi için Kullanılan Veri Setinin Duygulara Göre Popülerlik Dağılımı Grafiği

5.4.4 Duygu Analizi için Kullanılan Veri Setinin Türlere Göre Duygu Dağılımı

Duygu analizi için kullanılan veri setinin türlere göre duygu dağılımı Şekil 5.25'teki gibidir.



Şekil 5.25 Duygu Analizi için Kullanılan Veri Setinin Türlere Göre Duygu Dağılımı Grafiği

Duygu analizi için kullanılan veri setinin türlere göre duygu dağılımı Tablo 5.5'teki


gibidir.

Tablo 5.5 Duygu Analizi için Kullanılan Veri Setinin Türlerine Göre Duygu Dağılımı Tablosu

Genre	Anger	Disgust	Fear	Joy	Sadness	Surprise
Blues	269	138	616	96	226	183
Country	222	112	567	89	246	157
Hip-hop	266	105	536	99	206	141
Pop	220	82	645	111	277	202
R&B	23	13	53	9	27	14
Rock	188	69	527	78	227	180

5.4.5 Duygu Analizi için Kullanılan Veri Setinin Tür ve Duygulara Göre Ortalama Popülerlik Skorları Dağılımı

Duygu analizi için kullanılan veri setinin tür ve duygulara göre ortalama popülerlik skorları dağılımı grafiği Şekil 5.26'daki gibidir.



Şekil 5.26 Duygu Analizi için Kullanılan Veri Setinin Tür ve Duygulara Göre Ortalama Popülerlik Skorları Dağılımı Grafiği


Duygu analizi için kullanılan veri setinin tür ve duygulara göre ortalama popülerlik skorları dağılımı Tablo 5.6'daki gibidir.

Tablo 5.6 Duygu Analizi için Kullanılan Veri Setinin Tür ve Duygulara Göre Ortalama Popülerlik Skorlarının Yüzdelik Dağılımı Tablosu

Genre	Anger	Disgust	Fear	Joy	Sadness	Surprise
Blues	67.74	68.14	67.67	67.07	65.78	67.39
Country	61.23	63.39	59.43	58.73	56.47	60.11
Hip-hop	51.26	48.34	59.28	56.83	59.00	56.13
Pop	50.19	51.66	46.27	41.95	48.77	50.51
R&B	74.09	72.31	71.83	71.11	67.52	73.29
Rock	57.22	61.13	46.27	46.59	48.08	36.73

5.4.6 Duygu Analizi için Kullanılan Veri Setinin Yıllara Göre Ortalama Popülerlik Trendleri

Duygu analizi için kullanılan veri setinin yıllara göre ortalama popülerlik trendleri grafiği Şekil 5.27'deki gibidir.



Şekil 5.27 Duygu Analizi için Kullanılan Veri Setinin Yıllara Göre Ortalama Popülerlik Trendleri Grafiği

Not: Verisi olmayan yıllar 0 değeri ile gösterilmiştir.

5.4.7 Sonuçların Değerlendirilmesi

Bu bölümde, ulaşılan sonuçların analizi yapılacak ve şarkı sözlerinden etiketlenen duyguların ve bu duyguların müzik türleri ve popülerliği üzerindeki etkisi incelenecektir.

Gerçek veri kümesine üzerinde yapılan etiketleme işlemi sonucunda ‘fear’, ‘sadness’, ‘fear’ ve ‘disgust’ gibi negatif duyguların baskın olduğu gözlemlenmiştir. Bu duygular arasından ‘fear’ duygusu açık ara en fazla tespit edilen duygu olduğu görülmüştür. Bunun yanı sıra, ‘joy’ ve ‘surprise’ gibi pozitif duyguların ortalama popülerlik skorları ve etiketlenme sayılarının daha az olduğu görülmüştür. Bu verilerle birlikte, şarkı sözlerinde negatif duyguların dinleyicilerin ilgisini daha çok çektiği ve daha baskın olduğu gözlemlenmiştir.

Etiketlenen duyguların ortalama popülerlik skorlarını incelediğimizde negatif duyguların pozitiflere nazaran daha iyi skorlar aldığı gözlemlenmiştir. Bu veri, dinleyicilerin negatif duyguların daha baskın olduğu şarkıları dinlemeyi sevdiğini göstermektedir.

R&B ve Blues türleri, diğer türlere kıyasla duygu ve popülerlik verilerine göre ön plana çıkmıştır. Bu iki tür diğer türlere göre daha yüksek popülerlik skorlarına sahiptir. R&B türünde, ‘anger’, ‘disgust’ ve ‘fear’ gibi duyguların 70’in üzerinde ortalama popülerlik skorlarıyla öne çıkmaktadır. Bu iki tür duygusal yoğunluk ve negatif duyguların dinleyici bazında daha fazla ilgi gördüğü söylenebilir. Diğer türlerde ise hem ortalama popülerlik skorları hem de pozitif duyguların sayısının düşüşü gözlemlenmiştir.

Bu verilerle birlikte, müzikte duygunun, özellikle negatif duyguların popülerlik skorları yönünde belirgin etkisi olduğu söylenebilir. R&B ve Blues türleri, hem duygusal etiketin hem de bu etiketi gösteren şarkıların popülerliğiyle öne çıkmaktadır. Çalışmanın verileri, şarkı sözlerinde duygusal etiketin ve tür tercihlerinin, dinleyicileri şarkıları sevmesine ve böylece popüler hale gelmesine katkı sağladığı gözlemlenmiştir.

6 SONUÇ VE TARTIŞMA

Bu bölümde, yürütülen çalışmanın bir değerlendirmesi yapılacaktır. Burada, proje konusu ve benimsenen yöntemler özetlenecek; elde edilen bulguların özeti ifade edilecektir. Özellikle deneysel çalışmalarda, farklı deneylerden elde edilen ana sonuçlar değerlendirilerek karşılaştırmalar yapılacaktır. Ayrıca, bu çalışmanın başlangıçta belirlenen hedeflere ne ölçüde ulaştığı, üstün ve eksik yönleri ele alınarak gelecekteki çalışmalar için öneriler sunulacaktır.

6.1 Proje Konusunun ve Yöntemlerin Özeti

Proje kapsamında, şarkı sözlerinden duygu analizi yapılarak şarkı sözlerindeki duyguların popülerlik ve tür ile ilişkisi incelenmiştir. Bu doğrultuda, duygu analizi yapılabilmesi için BERT, RoBERTa ve DeBERTaV3 modelleri fine-tune edilmiştir. Modelleri daha iyi fine-tune edebilmek için daha önceden etiketlenmiş hazır veri kümesi üzerine augmentasyon ve sınırlama işlemleri uygulanmıştır. Fine-tune edilen modeller arasından en iyi performansı gösteren RoBERTa modeli seçilerek analiz yapılacak veri kümesindeki şarkıları etiketlemiştir. Duygu analizi yapılacak olan veri kümesinin geniş kapsamlı olması için şarkıların popülerlik ve türlerine göre Spotify ve Genius API'ları kullanılarak toplanmıştır.

6.2 Elde Edilen Sonuçların Değerlendirmesi

Yiyang Hong ve Yuqi Xue tarafından yapılan çalışmada [21], 1000 şarkı sözünden ve 'sadness', 'tenderness' ve 'tension' olmak üzere 3 etiket sınıfından oluşan veri kümesi kullanılarak BERT modeli ile bir eğitim işlemi yapılmış. Modelin, %67'lik bir genel doğruluk oranına ulaştığı, bu da test örneklerinin yaklaşık üçte ikisinin doğru bir şekilde sınıflandırıldığından bahsedilmiştir. Modelin ağırlıklı ortalama kesinliği, duyarlılığı ve F1 skoru değerleri sırasıyla %68, %67 ve %66'dır.

Revathy ve arkadaşları tarafından yapılan çalışmada [22], Music4All [23] veri

setindeki valance değerlerinden ‘happy’, ‘angry’, ‘sadness’ ve ‘relaxed’ duygu sınıfları belirlenmiştir. Bu belirlenen 4 duygu üzerinden LyEmoBERT modeli eğitilerek %78, kesinlik, duyarlılık ve F1 skoru değerlerine ulaşılmıştır.

Abdillah ve arkadaşları tarafından yapılan çalışmada [24], 2189 şarkıdan oluşan ve ‘happy’, ‘angry’, ‘sadness’ ve ‘relaxed’ olmak üzere 4 sınıfa sahip olan MoodLyrics [7] veri kümesi kullanılmıştır. Sınıflandırma için derin öğrenme tabanlı yöntemler kullanılmıştır. En yüksek başarı Bi-LSTM modeli ile %92 kesinlik, %90 duyarlılık, %91 doğruluk ve F1 skoru değerleri elde edilmiştir.

Darren Edmonds ve João Sedoc tarafından yapılan çalışmada [5]; ‘anger’, ‘disgust’, ‘fear’, ‘joy’, ‘sadness’ ve ‘surprise’ olmak üzere 6 duyguya sahip veri seti kullanılmıştır. BERT modeli ile en iyi sonuç olarak %83 doğruluk oranı elde edilmiştir.

Bu projede eğitilen RoBERTa modeli, üç veri kümesinde de en yüksek doğruluk ve F1 skorlarına ulaşarak BERT ve DeBERTaV3 modellerine göre üstün bir performans göstermiştir. En yüksek başarısını Dataset 2 ile eğitilen model ile %84 kesinlik, %85 duyarlılık ve F1 skoru elde etmiştir. Bu verilerle birlikte yukarıda bahsedilen diğer araştırmalara kıyasla modelimiz genel olarak daha başarılı olduğu gözlemlenmiştir.

Dataset 2’de uygulanan veri dengeleme ve veri artırma stratejilerinin modellerin performanslarını doğrudan etkilediği gözlemlenmiştir. Özellikle aynı anda azınlık sınıflardaki örneklerin artırılması ve diğer sınıflardaki örneklerle eşit sayıda tutulması, modellerin duyguları daha başarılı bir şekilde sınıflandırmasına önemli bir ölçüde katkı sağladığı sonucuna varılmıştır.

Eğittiğimiz RoBERTa modeli tarafından etiketlenen veriler üzerinde yapılan analizlerde, şarkı sözlerinde ‘fear’, ‘sadness’, ‘anger’ ve ‘disgust’ gibi olumsuz duyguların baskın olduğu ve bu duyguların popülerlikle pozitif bir ilişki içinde bulunduğu gözlemlenmiştir. Buna karşılık, ‘joy’ ve ‘surprise’ gibi olumlu duyguların hem sayıca az hem de ortalama popülerlik skorları bakımından daha düşük değerlere sahip olduğu gözlemlenmiştir. Bu durum sonucunda, müzikte şarkı sözlerindeki olumsuz duyguların hem daha fazla işlendiği hem de dinleyici tarafından daha fazla ilgi gördüğü sonucuna varılmıştır.

Müzik türlerine göre yapılan analizlerde ise R&B ve Blues türlerinin öne çıktığı gözlemlenmiştir. Bu türlerde ‘fear’, ‘sadness’, ‘anger’ ve ‘disgust’ gibi hem olumsuz duyguların yoğunluğu hem de bu duygularla ilişkilendirilen popülerlik düzeyleri diğer türlere göre belirgin bir şekilde yüksektir. Bu durum sonucunda, bu türlerin duygusal yoğunluğun ve sözlerde işlenen olumsuz duyguların dinleyiciyle daha güçlü bir duygusal bağ kurduğu sonucuna varılmıştır.

Tüm bu sonuçlar ile veri seti ve model seçiminin şarkı sözlerindeki duyguları sınıflandırmayı önemli bir şekilde etkilediği ve şarkı sözlerindeki duygusal içeriğin ve tür tercihlerinin, şarkıların dinleyiciyle buluşmasında ve popüler hale gelmesinde önemli bir rol oynadığı sonucuna varılmıştır.

6.3 Çalışmanın Güçlü ve Zayıf Yönleri

Bu çalışmada başlangıçta belirlenen hedeflere ulaşarak şarkı sözlerindeki duyguların tür ve popülerlik ile ilişkisi incelenmiştir. Çalışmanın hem metod hem de uygulama açısından öne çıkan güçlü yönleri olmakla birlikte, belirli sınırlılıklardan ötürü zayıf yönleri de bulunmaktadır.

6.3.1 Çalışmanın Güçlü Yönleri

Çalışmada sadece BERT modeli kullanılmamış, bu modelin dışında RoBERTa ve DeBERTaV3 modelleri karşılaştırmalı bir yaklaşımla değerlendirilerek duygu analizi için en uygun modelin belirlenmesi sağlanmış ve model seçim sürecine nesnel bir temel kazandırılmıştır.

Model eğitimleri için kullanılan veri seti direkt olarak kullanılmamış, çeşitli veri ön işleme adımlarından geçerek modellerin daha başarılı olması sağlanmıştır. Bununla da yetinilmeyip veri artırma ve sınırlandırma stratejileri uygulanarak farklı veri setleri oluşturulmuş ve bu veri setlerinin modellerin başarısındaki etkisi karşılaştırılmıştır.

Spotify ve Genius API'leri kullanılarak şarkı sözleriyle birlikte şarkılara ait tür ve popülerlik verileri de toplanmıştır. Gerçek hayat verileri üzerinde sadece sınıflandırma değil, ayrıca tür ve popülerite analizi yapılarak uygulama alanı genişletilmiştir. Böylece modelin pratikteki geçerliliği artırılmıştır.

Power Analysis yapılarak manuel etiketlenmesi gereken veri sayısı bulunmuş, gerçek hayattan toplanan veriden rastgele örnekler seçilmiş ve modelin Ground Truth değeri hesaplanmıştır. Bunun sayesinde modelin gerçek veri üzerindeki doğruluğu nesnel biçimde değerlendirilebilmiştir.

6.3.2 Çalışmanın Zayıf Yönleri

Eğitim veri setinde duygu sınıflarının dengesiz bir biçimde dağılmasından dolayı oldukça sentetik veri içeren Dataset 3'de modellerin diğer veri setlerine göre daha düşük performans sergilemesi, modellerin gerçek verilere kıyasla sentetik verilerden yeterince genellemediğini göstermektedir.

Bireysel etiketlemeler sonucunda elde edilen Cohen's Kappa değeri makul düzeyde olsa bile duygu etiketlemede bireyler arasında fikir birliği sağlanmasının zor olması, bu tür çalışmaların doğası gereği subjektif yorumlara açık olduğunu göstermektedir.

6.4 Öneriler

Bu çalışmada elde edilen sonuçlar, duygu analizi temelli müzik incelemeleri için güçlü bir temel sunarken gelecekte yapılacak benzer çalışmalar için çeşitli öneriler de sunmaktadır.

Veri setinin dengesiz olmasıyla birlikte bazı duyguların daha az örneğe sahip olmasıyla bu duyguların hem model eğitimi hem de gerçek veri analizlerinde yeterince temsil edilmediği gözlemlenmiştir. Gelecekte, bu duyguları daha dengeli şekilde içeren büyük ve çeşitlendirilmiş etiketli veri kümelerinin oluşturulması sınıflandırma başarımını artıracaktır.

Bu çalışmada BERT, RoBERTa ve DeBERTaV3 modelleriyle başarılı sonuçlar elde edilmiş olsa da, farklı BERT tabanlı modeller ve hatta başka derin öğrenme ya da makine öğrenmesi tabanlı modellerin de kullanılarak performans değerlendirilmesi yapılması önerilmektedir.

Şarkı sözlerinin haricinde müzikal öğelere de yer verilerek şarkıların duygu sınıflandırması daha iyi bir şekilde yapılabilir. Bu sayede duygu tespiti sadece metinsel değil, sesli verilere dayalı olarak da desteklenmiş olur.

- [1] D. Khurana, A. Koli, K. Khatter, and S. Singh, “Natural language processing: State of the art, current trends and challenges,” *Multimedia Tools and Applications*, vol. 82, no. 3, pp. 3713–3744, Jan. 2023, ISSN: 1573-7721. DOI: 10.1007/s11042-022-13428-4. [Online]. Available: <https://doi.org/10.1007/s11042-022-13428-4>.
- [2] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, *Bert: Pre-training of deep bidirectional transformers for language understanding*, 2019. arXiv: 1810.04805 [cs.CL]. [Online]. Available: <https://arxiv.org/abs/1810.04805>.
- [3] D. Khurana, A. Koli, K. Khatter, and S. Singh, “Natural language processing: State of the art, current trends and challenges,” *Multimedia Tools and Applications*, vol. 82, no. 3, pp. 3713–3744, Jul. 2022, ISSN: 1573-7721. DOI: 10.1007/s11042-022-13428-4. [Online]. Available: <http://dx.doi.org/10.1007/s11042-022-13428-4>.
- [4] R. Plutchik, “The nature of emotions: Human emotions have deep evolutionary roots, a fact that may explain their complexity and provide tools for clinical practice,” *American Scientist*, vol. 89, no. 4, pp. 344–350, 2001, ISSN: 00030996. [Online]. Available: <http://www.jstor.org/stable/27857503> (visited on 03/27/2025).
- [5] D. Edmonds and J. Sedoc, “Multi-emotion classification for song lyrics,” in *Proceedings of the Eleventh Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis*, O. De Clercq et al., Eds., Online: Association for Computational Linguistics, Apr. 2021, pp. 221–235. [Online]. Available: <https://aclanthology.org/2021.wassa-1.24/>.
- [6] C. Lechner, “Recognizing emotions in music,” Available at: <https://diglib.uibk.ac.at/download/pdf/10363290.pdf>, M.S. thesis, Universität Innsbruck, Innsbruck, Austria, Sep. 2024.
- [7] E. Çano and M. Morisio, “Moodylyrics: A sentiment annotated lyrics dataset,” in *Proceedings of the 2017 International Conference on Intelligent Systems, Metaheuristics & Swarm Intelligence*, ser. ISMSI ’17, Hong Kong, Hong Kong: Association for Computing Machinery, 2017, pp. 118–124, ISBN: 9781450347983. DOI: 10.1145/3059336.3059340. [Online]. Available: <https://doi.org/10.1145/3059336.3059340>.
- [8] Y. Agrawal, R. G. R. Shanker, and V. Alluri, “Transformer-based approach towards music emotion recognition from lyrics,” in *Advances in Information Retrieval*. Springer International Publishing, 2021, pp. 167–175, ISBN: 9783030722401.

- [9] Y.-H. Yang, Y.-C. Lin, Y.-F. Su, and H. H. Chen, "A regression approach to music emotion recognition," *IEEE Transactions on Audio, Speech, and Language Processing*, vol. 16, no. 2, pp. 448–457, 2008. DOI: 10.1109/TASL.2007.911513.
- [10] R. Malheiro, R. Panda, P. Gomes, and R. P. Paiva, "Emotionally-relevant features for classification and regression of music lyrics," *IEEE Transactions on Affective Computing*, vol. 9, no. 2, pp. 240–254, 2018. DOI: 10.1109/TAFFC.2016.2598569.
- [11] D. Yang and W.-S. Lee, "Music emotion identification from lyrics," in *2009 11th IEEE International Symposium on Multimedia*, 2009, pp. 624–629. DOI: 10.1109/ISM.2009.123.
- [12] E. N. Shaday, V. J. L. Engel, and H. Heryanto, "Application of the bidirectional long short-term memory method with comparison of word2vec, glove, and fasttext for emotion classification in song lyrics," *Procedia Computer Science*, vol. 245, pp. 137–146, 2024, 9th International Conference on Computer Science and Computational Intelligence 2024 (ICCSCI 2024), ISSN: 1877-0509. DOI: <https://doi.org/10.1016/j.procs.2024.10.237>. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S187705092403045X>.
- [13] B.-H. Sung and S.-C. Wei, "Becmer: A fusion model using bert and cnn for music emotion recognition," in *2021 IEEE 22nd International Conference on Information Reuse and Integration for Data Science (IRI)*, 2021, pp. 437–444. DOI: 10.1109/IRI51335.2021.00068.
- [14] D. Martín-Gutiérrez, G. Hernández-Peñaloza, A. Belmonte-Hernández, and F. Álvarez, *Spotgentrack popularity dataset*, Online, Jul. 2019. [Online]. Available: <https://www.kaggle.com/datasets/saurabhshahane/spotgen-music-dataset>.
- [15] H. Agatha, F. Putri, and A. Suryadibrata, "Sentiment analysis on song lyrics for song popularity prediction using bert," *Ultimatics : Jurnal Teknik Informatika*, vol. 15, pp. 99–105, Jan. 2024. DOI: 10.31937/ti.v15i2.3420.
- [16] Manoh2f2 and Tsterbak, *Lyrics dataset with emotions*, <https://huggingface.co/datasets/manoh2f2/tsterbak-lyrics-dataset-with-emotions>.
- [17] P. Damodaran, *Parrot: Paraphrase generation for nlu*. Version v1.0, 2021.
- [18] A. Vaswani *et al.*, "Attention is all you need," *CoRR*, vol. abs/1706.03762, 2017. arXiv: 1706.03762. [Online]. Available: <http://arxiv.org/abs/1706.03762>.
- [19] Y. Liu *et al.*, "Roberta: A robustly optimized BERT pretraining approach," *CoRR*, vol. abs/1907.11692, 2019.
- [20] P. He, J. Gao, and W. Chen, *Debertav3: Improving deberta using electra-style pre-training with gradient-disentangled embedding sharing*, 2021. arXiv: 2111.09543 [cs.CL].
- [21] Y. Hong and Y. Xue, "Emotion classification through song lyrics in multi-languages with bert," *Applied and Computational Engineering*, vol. 134, pp. 123–132, Feb. 2025. DOI: 10.54254/2755-2721/2025.21293.

- [22] V. R. Revathy, A. S. Pillai, and F. Daneshfar, "Lyemobert: Classification of lyrics' emotion and recommendation using a pre-trained model," *Procedia Computer Science*, vol. 218, pp. 1196–1208, 2023, International Conference on Machine Learning and Data Engineering, ISSN: 1877-0509. DOI: <https://doi.org/10.1016/j.procs.2023.01.098>. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1877050923000984>.
- [23] I. A. Pegoraro Santana *et al.*, "Music4all: A new music database and its applications," in *2020 International Conference on Systems, Signals and Image Processing (IWSSIP)*, 2020, pp. 399–404. DOI: 10.1109/IWSSIP48289.2020.9145170.
- [24] J. Abdillah, I. Asror, and Y. Wibowo, "Emotion classification of song lyrics using bidirectional lstm method with glove word representation weighting," *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, vol. 4, pp. 723–729, Aug. 2020. DOI: 10.29207/resti.v4i4.2156.

BİRİNCİ ÜYE

İsim-Soyisim: Melih YELMAN

Doğum Tarihi ve Yeri: 28.01.2001, İstanbul

E-mail: melih.yelman@std.yildiz.edu.tr

Telefon: 0537 603 41 36

Staj Tecrübeleri: SteelOrbis Şirketi Yazılım Departmanı

İKİNCİ ÜYE

İsim-Soyisim: Tarık TAŞKIN

Doğum Tarihi ve Yeri: 29.10.2003, İstanbul

E-mail: tarik.taskin@std.yildiz.edu.tr

Telefon: 0539 526 73 40

Staj Tecrübeleri: Henüz yok

Proje Sistem Bilgileri

Sistem ve Yazılım: Windows İşletim Sistemi, Python

Gerekli RAM: 8 GB

Gerekli Disk: 4 GB